

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

NGUYỄN THỊ MINH

NGHIÊN CỨU PHƯƠNG PHÁP PHÂN TÍCH HÀNH VI
CỦA KHÁCH HÀNG

LUẬN VĂN THẠC SỸ: NGÀNH HỆ THỐNG THÔNG TIN

Hà Nội - 2023

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

NGUYỄN THỊ MINH

NGHIÊN CỨU PHƯƠNG PHÁP PHÂN TÍCH HÀNH VI
CỦA KHÁCH HÀNG

Ngành: Hệ thống thông tin

chuyên ngành: Hệ thống thông tin

Mã số: 60480104

LUẬN VĂN THẠC SỸ: NGÀNH HỆ THỐNG THÔNG TIN

NGƯỜI HƯỚNG DẪN KHOA HỌC: TIẾN SĨ NGUYỄN THỊ HẬU

Hà Nội - 2023

LỜI CẢM ƠN

Trước tiên, tác giả xin bày tỏ lòng biết ơn chân thành và sâu sắc tới Tiến sĩ Nguyễn Thị Hậu vì đã tận tình chỉ bảo và giúp đỡ tác giả rất nhiều trong suốt quá trình học tập và thực hiện Luận văn thạc sỹ. Tác giả cũng muốn gửi lời cảm ơn đến tất cả thầy cô trong Khoa Công nghệ thông tin và trường Đại học Công nghệ - Đại học Quốc gia Hà Nội, những người đã dạy dỗ và truyền cảm hứng học tập, tìm hiểu trong suốt hơn 02 năm học Thạc sỹ vừa qua của tác giả. Cuối cùng, tác giả xin trân trọng gửi lời cảm ơn đến bố mẹ, gia đình và bạn bè vì đã luôn bên cạnh và động viên tác giả trong suốt quá trình học tập.

Hà Nội, ngày ... tháng ... năm 2023

Tác giả

Nguyễn Thị Minh

LỜI CAM ĐOAN

Tác giả xin cam đoan các kĩ thuật và phương pháp mà tác giả sử dụng trong bài toán Nghiên cứu phương pháp dự đoán hành vi của khách hàng được trình bày trong luận văn là do tác giả thực hiện, dưới sự hướng dẫn của TS. Nguyễn Thị Hậu. Mọi tham khảo được trình bày trong luận văn thạc sĩ này từ các công trình nghiên cứu khác đều được trích dẫn đầy đủ và rõ ràng, không có sự sao chép tài liệu hay công trình của người khác. Nếu có, tác giả xin hoàn toàn chịu trách nhiệm theo quy định của trường Đại học Công nghệ - Đại học Quốc gia Hà Nội.

Hà Nội, ngày ... tháng ... năm 2023

Tác giả

Nguyễn Thị Minh

MỤC LỤC

Lời cảm ơn	2
Lời cam đoan	3
Mục lục	4
Danh mục hình vẽ	6
Danh mục bảng biểu	7
Mở đầu	8
CHƯƠNG 1. GIỚI THIỆU BÀI TOÁN VÀ TỔNG QUAN LÝ THUYẾT	11
1.1. Giới thiệu bài toán	11
1.2. Phát biểu bài toán	12
1.3. Các đặc trưng dữ liệu của bài toán Dự đoán tần suất mua hàng, dự đoán rời bỏ dịch vụ của khách hàng	12
1.4. Tổng quan các nghiên cứu liên quan	13
1.4.1. Phương pháp tiền xử lý dữ liệu	13
1.4.2. Kỹ thuật học máy để dự đoán hành vi của khách hàng	18
1.4.3. Phương pháp đánh giá mô hình	38
CHƯƠNG 2. QUY TRÌNH ĐỀ XUẤT DỰ ĐOÁN HÀNH VI KHÁCH HÀNG	43
2.1. Tìm kiếm và lựa chọn dữ liệu	43
2.2. Tiền xử lý dữ liệu	48
2.2.1. Làm sạch dữ liệu	48
2.2.2. Xử lý dữ liệu phân loại	48
2.2.3. Biến đổi dữ liệu	48
2.2.4. Chuẩn hóa dữ liệu	49
2.2.5. Xử lý dữ liệu mất cân bằng	50
2.3. Trích chọn đặc trưng	50
2.4. Xây dựng mô hình phân lớp hành vi khách hàng	52
2.4.1. Tối ưu hóa siêu tham số	52
2.4.2. Các phương pháp học kết hợp được đề xuất	53
2.5. Kiểm thử chéo, đưa ra kết quả và phân tích	57
CHƯƠNG 3. KỊCH BẢN VÀ KẾT QUẢ THỰC NGHIỆM	59
3.1. Kết quả tiền xử lý dữ liệu và so sánh với các nghiên cứu liên quan	59
3.1.1. Làm sạch dữ liệu	59
3.1.2. Xử lý dữ liệu phân loại	59
3.1.3. Xử lý dữ liệu mất cân bằng	60

3.1.4. So sánh các bước tiền xử lý dữ liệu của luận văn với một số nghiên cứu liên quan sử dụng cùng bộ dữ liệu	60
3.2. Kết quả trích chọn đặc trưng và so sánh với các nghiên cứu liên quan sử dụng cùng bộ dữ liệu	62
3.2.1. Kết quả trích chọn đặc trưng của các bộ dữ liệu	62
3.2.2. So sánh kỹ thuật trích chọn đặc trưng của luận văn với một số nghiên cứu liên quan	62
3.3. Kết quả xây dựng mô hình phân lớp hành vi khách hàng và so sánh với các nghiên cứu liên quan	65
3.3.1. Kết quả tối ưu hóa siêu tham số	65
3.3.2. Kết quả hiệu suất mô hình phân lớp hành vi khách hàng và phân tích kết quả	66
Kết luận	72
TÀI LIỆU THAM KHẢO	73

DANH MỤC HÌNH VẼ

Hình 1.1	Ví dụ mô hình FNN [29].	34
Hình 1.2	Kiến trúc tổng quan của mô hình xếp chồng [39].	37
Hình 2.1	Quy trình đề xuất dự đoán hành vi của khách hàng.	44
Hình 2.2	Mô hình Xếp chồng đề xuất với tám thuật toán.	55
Hình 2.3	Mô hình voting đề xuất với tám thuật toán.	57
Hình 3.1	Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Cell2cell.	63
Hình 3.2	Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Campaign.	63
Hình 3.3	Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Bank.	64
Hình 3.4	Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Customer shopping trends.	64

DANH MỤC BẢNG BIỂU

Bảng 1.1	Tổng hợp các bước tiền xử lý dữ liệu sử dụng trong các nghiên cứu trước đây	14
Bảng 1.2	Tổng hợp các phương pháp, thuật toán phân lớp được sử dụng trong một số nghiên cứu cập nhật	19
Bảng 1.3	Phương pháp đánh giá mô hình dự đoán hành vi khách hàng.	39
Bảng 2.1	Tóm tắt các bộ dữ liệu được sử dụng	45
Bảng 3.1	Kết quả của một số bước trong quá trình tiền xử lý dữ liệu	60
Bảng 3.2	Siêu tham số của các mô hình phân lớp	66
Bảng 3.3	Độ đo AUC của các mô hình phân lớp	68
Bảng 3.4	Độ đo F1 của các mô hình phân lớp	68
Bảng 3.5	So sánh hiệu suất mô hình giữa luận văn và các nghiên cứu trước đây	69

MỞ ĐẦU

Dự đoán hành vi của khách hàng là một trong những mối quan tâm hàng đầu của các doanh nghiệp lớn, vì nó có tác động trực tiếp đến việc tạo doanh thu. Việc này liên quan đến việc sử dụng dữ liệu và các kỹ thuật mô hình dự đoán để dự báo hành vi, sở thích và hành động của khách hàng. Khi nghiên cứu hành vi khách hàng, có nhiều bài toán khác nhau: dự đoán hành vi rời bỏ, dự đoán hành vi mua lặp lại, dự đoán hành vi mua lần đầu, dự đoán tần suất hành vi mua,... Luận văn tập trung nghiên cứu hai bài toán dự đoán khách hàng rời bỏ (customer churn prediction) và dự đoán tần suất mua hàng của khách hàng (frequency of customer purchase prediction) do quá trình tiền xử lý dữ liệu cho hai bài toán này khá tương đồng. Điều này sẽ được thảo luận kỹ hơn trong phần sau. Hai bài toán luận văn tập trung cũng đã thu hút sự quan tâm nhất định của cộng đồng nghiên cứu, chẳng hạn: [5, 8, 24, 34, 47]. Hai bài toán này cực kỳ quan trọng vì chúng đều có chung mục đích giữ chân khách hàng hiện tại, điều này đã được chứng minh là tiết kiệm chi phí hơn gấp nhiều lần so với việc thu hút khách hàng mới với tỷ suất lợi nhuận đáng kể [26, 41].

Tuy nhiên, trong các nghiên cứu liên quan, hai bài toán dự đoán khách hàng rời bỏ và dự đoán tần suất mua hàng của khách hàng đều thực hiện độc lập. Không giống như các vấn đề phân loại thông thường, dự đoán hành vi của khách hàng liên quan đến nhiều khía cạnh của hoạt động tương tác với khách hàng, chẳng hạn như chuyển đổi, tần suất mua hàng và mức độ tương tác với các chiến dịch tiếp thị. Nó đưa ra những thách thức đặc biệt, bao gồm dữ liệu thưa, sự mất cân bằng giữa các lớp hành vi, sự phụ thuộc vào thời gian và nhu cầu về khả năng diễn giải. Luận văn được thực hiện nhằm mục đích giải quyết những khác biệt này thông qua việc tận dụng chúng để xây dựng quy trình đề xuất dự đoán hành vi khách hàng.

Liên quan đến dự đoán hành vi khách hàng, nhiều kỹ thuật trích chọn đặc trưng (Feature Selection - FS) khác nhau đã được đề xuất để dự đoán hành vi khách hàng. ACO-RSA kết hợp giữa ACO và RSA cho thấy hiệu quả vượt trội so với các thuật toán khác như PSO, MVO, GWO, standard ACO, and standard RSA [2]. Các phương pháp FS đầy hứa hẹn khác bao gồm thuật toán Relief-F cải tiến [1] và xây dựng tính năng Nhóm cách đều [48]. Tuy nhiên, những phương pháp này có những hạn chế, được thảo luận trong phần sau của luận văn.

Các nghiên cứu trước đây giải quyết hai bài toán dự đoán rời bỏ và dự đoán tần suất mua hàng của khách hàng đã sử dụng đa dạng các thuật toán và phương pháp học máy khác nhau và so sánh hiệu suất của chúng thông qua việc sử dụng nhiều bộ dữ liệu để

xác định các phương pháp hiệu quả nhất. Chẳng hạn, Bogaert và Delaere (2023) đã tiến hành một nghiên cứu thử nghiệm toàn diện về dự đoán hành vi của khách hàng, đánh giá 33 bộ phân lớp, bao gồm 6 thuật toán học máy truyền thống 14 bộ phân lớp kết hợp không đồng nhất và 13 bộ phân lớp kết hợp đồng nhất trên 11 tập dữ liệu [5]. Những phát hiện của họ đã chứng minh một cách nhất quán rằng các phương pháp bộ phân lớp kết hợp không đồng nhất hoạt động tốt hơn các phương pháp bộ phân lớp tổng hợp đồng nhất và các thuật toán học máy truyền thống. Hơn nữa, các nghiên cứu gần đây đã cho thấy những kết quả đầy hứa hẹn khi sử dụng các mô hình học sâu để dự đoán hành vi của khách hàng [12, 17, 32].

Nhìn chung, các phương pháp học kết hợp (Ensemble Learning) và các thuật toán học sâu (Deep Learning) đã cho thấy hiệu suất được cải thiện trong các mô hình dự đoán so với các thuật toán riêng lẻ [5, 9, 14, 24, 32, 43]. Tuy nhiên, các phương pháp học kết hợp thường dựa vào các thuật toán học máy truyền thống với vai trò là mô hình học máy cơ sở và hiếm khi kết hợp đồng thời thuật toán tăng cường, đóng bao và học sâu với vai trò là mô hình học máy cơ sở.

Để giải quyết những hạn chế đã nêu, quy trình đề xuất dự đoán hành vi khách hàng của luận văn nhằm mục đích thực hiện các đóng góp chính như sau:

(1) Dự đoán đồng thời hành vi rời bỏ và tần suất mua hàng của khách hàng: quy trình đề xuất dự đoán hành vi khách hàng của luận văn cung cấp một quy trình để dự đoán đồng thời tần suất mua hàng và rời bỏ của khách hàng, lấp đầy khoảng trống nghiên cứu và cung cấp cho doanh nghiệp sự hiểu biết toàn diện về động lực của khách hàng. Luận văn xác thực tính hiệu quả và tính linh hoạt của mô hình thông qua việc sử dụng bốn bộ dữ liệu phù hợp với những thách thức trong việc dự đoán tần suất mua hàng và rời bỏ của khách hàng.

(2) Luận văn trình bày một phương pháp trích chọn đặc trưng mới thông qua việc sử dụng hồi quy đa biến. Phương pháp này xác định một cách hiệu quả các đặc điểm có ảnh hưởng tác động đáng kể đến biến đầu ra, vượt qua các hạn chế của các phương pháp trích chọn đặc trưng hiện có và nâng cao hiệu suất mô hình. Thông qua việc xem xét các đặc điểm độc đáo của phân tích hành vi khách hàng so với các vấn đề phân loại truyền thống, cách tiếp cận của luận văn xác định chính xác các đặc điểm có ảnh hưởng ảnh hưởng mạnh đến biến đầu ra. Cách tiếp cận đổi mới này có khả năng nâng cao độ chính xác và khả năng diễn giải của các mô hình phân tích hành vi khách hàng.

(3) Quy trình đề xuất dự đoán hành vi khách hàng của luận văn tích hợp phương pháp học kết hợp và học sâu, kết hợp các thuật toán tăng cường, đóng bao và học sâu làm mô hình học máy cơ sở để cải thiện hiệu suất dự đoán cho hành vi của khách hàng. Phương pháp đề xuất giúp thúc đẩy khả năng của thuật toán học sâu trong việc nắm bắt các mẫu và cách trình bày phức tạp trong dữ liệu khách hàng, nâng cao hiểu biết về các

hành vi phức tạp so với các vấn đề phân loại thông thường. Học kết hợp mang lại hiệu suất tốt cho dữ liệu nhiễu hoặc dữ liệu ngoại lai, đồng thời đưa ra các góc nhìn đa dạng để đưa ra dự đoán chính xác. Trong đóng góp này, luận văn tiến hành thử nghiệm các kỹ thuật học tập tập hợp như Xếp chồng (Stacking) và Bỏ phiếu (Voting). Luận văn đã sử dụng nhiều thuật toán làm mô hình học máy cơ sở, bao gồm thuật toán tăng cường (Xgboost, Adaboost, Catboost, LightGBM), thuật toán đóng bao (Random Forest), thuật toán học sâu (CNN, FNN) và Hồi quy logistic. Các phương pháp Xếp chồng và Bỏ phiếu được sử dụng như sau:

- Phương pháp Xếp chồng (Stacking): Luận văn sử dụng Logistic Regression (với vai trò là một mô hình phân lớp) làm meta-model. Theo đó, kết quả dự đoán các thuật toán được lựa chọn làm mô hình phân lớp cơ sở là đầu vào để Logistic Regression đưa ra dự đoán cuối cùng.
- Phương pháp Bỏ phiếu (Voting): Ngoài các phương pháp bỏ phiếu mềm (soft voting) và bỏ phiếu cứng (hard voting) truyền thống, luận văn đã sử dụng giải thuật tiến hóa (evolutionary algorithm) để xác định trọng số tối ưu cho các mô hình phân lớp cơ sở. Dự đoán cuối cùng về hành vi của khách hàng được đưa ra dựa trên quá trình bỏ phiếu với các trọng số đã được xác định.

Thông qua việc tích hợp các phương pháp Xếp chồng và Bỏ phiếu, luận văn hướng đến việc tận dụng những thế mạnh được cung cấp bởi các thuật toán tăng cường (Boosting), đóng bao (Bagging) và học sâu (Deep learning). Từ đó, khả năng dự đoán của các mô hình được tối ưu hóa và nâng cao hiệu suất tổng thể của chúng.

Phần còn lại của luận văn được tổ chức như sau:

Chương 1 của luận văn giới thiệu bài toán và trình bày tổng quan lý thuyết liên quan. Chi tiết các bước trong quy trình phân lớp hành vi khách hàng đề xuất được mô tả tại **Chương 2**. **Chương 3** thể hiện kịch bản và kết quả thực nghiệm của luận văn, bao gồm phân tích chuyên sâu thông qua các chỉ số hiệu suất và so sánh với kết quả của các nghiên cứu trước đây. Phần Kết luận được trình bày cuối cùng, bao gồm tóm lược các kết quả chính đạt được trong luận văn và hướng phát triển trong tương lai.

Các kết quả nghiên cứu của luận văn đã được công bố trong báo cáo tham dự hội nghị SOICT 2023 ¹

¹Thi Minh Nguyen, Thi An Le, and Thi Hau Nguyen. 2023. A flexible framework for customer behavior prediction based on ensemble learning. In The 12th International Symposium on Information and Communication Technology (SOICT 2023), December 07–08, 2023, Ho Chi Minh, Vietnam. ACM, New York, NY, USA. <https://doi.org/10.1145/3628797.3628973>

CHƯƠNG 1

GIỚI THIỆU BÀI TOÁN VÀ TỔNG QUAN LÝ THUYẾT

1.1. Giới thiệu bài toán

Khách hàng đóng vai trò vô cùng quan trọng trong mọi doanh nghiệp và hành vi khách hàng là yếu tố quyết định trong quá trình tương tác giữa khách hàng và doanh nghiệp. Theo Philip Kotler, “Hành vi của khách hàng là cách những cá thể, nhóm và tổ chức triển khai lựa chọn, mua, sử dụng và vô hiệu sản phẩm và hàng hóa, dịch vụ, sáng tạo độc đáo và thưởng thức để thỏa mãn nhu cầu nhu yếu và mong ước của họ” [22].

Dựa trên dữ liệu lịch sử về quá trình lựa chọn, mua, sử dụng, vô hiệu hóa sản phẩm và hàng hóa, dịch vụ, doanh nghiệp có thể xây dựng mô hình dự đoán hành vi của khách hàng, từ đó giữ chân khách hàng hiện tại. Dự đoán hành vi khách hàng là một vấn đề quan trọng mà các doanh nghiệp quan tâm bởi nó giúp họ hiểu rõ hơn về nhu cầu, mong muốn và hành vi của khách hàng. Theo Philip Kotler [23], dự đoán hành vi khách hàng được định nghĩa là "quá trình sử dụng dữ liệu và thông tin về khách hàng để dự báo và ước tính cách khách hàng sẽ tương tác, phản ứng và thực hiện quyết định trong tương lai. Điều này thường được thực hiện thông qua việc áp dụng các phương pháp phân tích dữ liệu, mô hình hóa và các kỹ thuật khác để hiểu và dự đoán hành vi của khách hàng".

Luận văn tập trung vào giải quyết bài toán xây dựng mô hình dự đoán hành vi của khách hàng dựa trên hai loại hành vi chính: hành vi rời bỏ và tần suất mua hàng của khách hàng. Với mỗi loại hành vi, luận văn sử dụng các bộ dữ liệu như sau:

- Ba bộ dữ liệu về hành vi rời bỏ của khách hàng:
 - Bộ dữ liệu Cell2cell¹ bao gồm 71,047 bản ghi và 71 cột
 - Bộ dữ liệu Campaign² bao gồm 41,188 bản ghi và 17 cột
 - Bộ dữ liệu Bank³ bao gồm 10,000 bản ghi và 12 cột
- Customer Shopping Trends⁴ bao gồm 3,900 bản ghi và 18 cột

Dựa trên các kết quả phân tích của mô hình, doanh nghiệp có thể hiểu được nhu cầu của khách hàng và đưa ra các quyết định kinh doanh liên quan đến chiến lược định giá, các kênh tiếp thị và cơ hội bán hàng bổ sung.

¹<https://www.kaggle.com/jpacse/telecom-churn-new-cell2cell-dataset>.

²<https://archive.ics.uci.edu/dataset/222/bank+marketing>.

³<https://www.kaggle.com/datasets/shrutimechlearn/churn-modelling>.

⁴https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset?select=shopping_trends_updated.csv.

1.2. Phát biểu bài toán

Bài toán xây dựng mô hình dự đoán hành vi của khách hàng được mô tả với đầu vào và đầu ra như sau:

- **Đầu vào:** Bài toán này tập trung vào việc dự đoán hành vi mua hàng hoặc rời bỏ của khách hàng dựa trên một tập hợp các trường dữ liệu. Đầu vào của bài toán được biểu diễn bởi tập $X = x_1, \dots, x_n$, trong đó, $x_1, \dots, x_n$ là các trường dữ liệu của bộ dữ liệu được sử dụng. Chúng có thể là dữ liệu số hoặc dữ liệu phân loại, được mô tả kỹ hơn trong phần sau.
- **Đầu ra:** Dự đoán tần suất mua hàng của khách hàng, rời bỏ/chưa rời bỏ trong tương lai. Trong đó:
 - y là nhãn được gán cho người dùng.
 - Đối với bộ dữ liệu sử dụng để dự đoán tần suất mua hàng với nhãn từ 1 đến 6, tương ứng với tần suất mua hàng của khách hàng đạt mức hàng tuần, Hai tuần một lần, hàng tháng, 3 tháng một lần, hàng quý, Hàng năm.
 - Đối với bộ dữ liệu sử dụng để dự đoán hành vi rời bỏ, nhãn 0 tương ứng với khách hàng có khả năng chưa rời bỏ sản phẩm, dịch vụ, ngược lại, nhãn 1 thể hiện khách hàng có khả năng rời bỏ sản phẩm, dịch vụ trong tương lai.

1.3. Các đặc trưng dữ liệu của bài toán Dự đoán tần suất mua hàng, dự đoán rời bỏ dịch vụ của khách hàng

Các đặc trưng dữ liệu của bài toán dự đoán tần suất mua hàng và dự đoán rời bỏ dịch vụ của khách hàng có những yếu tố đặc thù và đòi hỏi các phương pháp và kỹ thuật riêng biệt so với phân lớp thông thường. Việc phân loại hành vi khách hàng và phân lớp thông thường đều là những vấn đề quan trọng trong lĩnh vực phân tích dữ liệu và học máy.

- **Lịch sử giao dịch:** Các trường dữ liệu này liên quan đến thông tin về các giao dịch trước đó của khách hàng. Có thể phân loại thành các giao dịch cụ thể hoặc tính toán các thống kê dựa trên lịch sử giao dịch.
 - Kiểu dữ liệu: Số hoặc phân loại. Ví dụ, số tiền giao dịch, loại giao dịch (mua hàng, hoàn trả), thời gian giao dịch.
- **Tần suất:** Các trường dữ liệu này liên quan đến tần suất mua hàng của khách hàng trong một khoảng thời gian cụ thể. Có thể đếm số lần mua hàng hoặc chia thành các khoảng tần suất.
 - Kiểu dữ liệu: Số nguyên hoặc phân loại. Ví dụ, số lần mua hàng trong 1 tháng, khoảng tần suất (như "thấp", "trung bình", "cao").

- Tương tác khách hàng: Các trường dữ liệu này liên quan đến tương tác của khách hàng với hệ thống, chẳng hạn như số lần truy cập vào ứng dụng, số lần xem sản phẩm, số lần thực hiện giao dịch, v.v. Có thể đếm số lần tương tác hoặc tính toán các thống kê dựa trên tương tác.
 - Kiểu dữ liệu: Số nguyên hoặc phân loại. Ví dụ, số lần truy cập, số lần xem sản phẩm, mức độ tương tác (như "thấp", "trung bình", "cao").
- Đặc điểm khách hàng: Các trường dữ liệu này liên quan đến các thông tin cá nhân của khách hàng, chẳng hạn như độ tuổi, giới tính, địa chỉ, thu nhập, v.v. Có thể phân loại hoặc tính toán các thống kê dựa trên đặc điểm khách hàng.
 - Kiểu dữ liệu: Phân loại hoặc số. Ví dụ, giới tính (như "nam", "nữ"), độ tuổi (số nguyên), thu nhập (số hoặc khoảng giá trị).
- Đặc trưng khác: thông tin về sản phẩm/dịch vụ,... Các trường dữ liệu này liên quan đến thông tin về sản phẩm/dịch vụ, chẳng hạn như danh mục, danh mục con, thương hiệu, đặc điểm sản phẩm, v.v. Có thể phân loại hoặc tính toán các thống kê dựa trên đặc trưng khác.
 - Kiểu dữ liệu: Phân loại hoặc số. Ví dụ, danh mục sản phẩm (như "điện thoại", "máy tính"), đặc điểm sản phẩm (như "màn hình cảm ứng", "hỗ trợ 4G").

1.4. Tổng quan các nghiên cứu liên quan

Trong phần này, luận văn trình bày tóm tắt ngắn gọn về các nghiên cứu liên quan đến dự đoán hành vi của khách hàng đối với sản phẩm và dịch vụ, được công bố trong các tạp chí, hội nghị uy tín. Các nghiên cứu này được tóm tắt dựa trên ba khía cạnh chính: phương pháp tiền xử lý dữ liệu, kỹ thuật học máy để dự đoán hành vi khách hàng và phương pháp đánh giá mô hình.

1.4.1. Phương pháp tiền xử lý dữ liệu

Tiền xử lý dữ liệu đóng vai trò là nền tảng cơ bản trong lĩnh vực khai thác dữ liệu, phục vụ cho việc tinh chỉnh và chất lọc các bộ dữ liệu thô thành thông tin có ý nghĩa. Quy trình này bao gồm việc chỉnh sửa các điểm không nhất quán, giảm thiểu các giá trị bị thiếu hoặc rỗng và chỉnh sửa các phân phối lớp bị sai lệch [24]. Hơn nữa, việc xác định và lựa chọn các đặc trưng thích hợp đồng thời loại bỏ các đặc trưng thừa và nhiễu là những nhiệm vụ quan trọng, có khả năng nâng cao độ chính xác, hiệu quả bộ nhớ và tốc độ tính toán của các mô hình dự đoán.

Trong nghiên cứu trước đây về chủ đề dự đoán hành vi khách hàng, quá trình tiền xử lý dữ liệu đã được thực hiện thông qua nhiều bước khác nhau nhằm mục đích nâng cao chất lượng dữ liệu trước khi phân tích. Quá trình này thường diễn ra từ một đến 6

Bảng 1.1. Tổng hợp các bước tiền xử lý dữ liệu sử dụng trong các nghiên cứu trước đây

Nguồn	Số bước	Các bước tiền xử lý dữ liệu
[7]	6	(1) Xử lý các giá trị bị thiếu (2) Loại bỏ các giá trị ngoại lai (3) Mã hóa các biến phân loại (4) Chuẩn hóa dữ liệu (5) Giải quyết sự mất cân bằng lớp (6) Trích chọn đặc trưng
[12]	5	(1) Xử lý dữ liệu bị thiếu (2) Mã hóa các trường dữ liệu phân loại (3) Chuẩn hóa các giá trị có phương sai cao (4) Trích chọn đặc trưng (5) Xử lý mất cân bằng lớp
[33]	4	(1) Xử lý các ID mẫu đặc trưng trùng lặp và các giá trị số bị thiếu (2) Chuyển đổi từ hạng mục sang số (3) Biến đổi dữ liệu (4) Trích chọn đặc trưng
[20]	3	(1) Loại bỏ các bản ghi có giá trị bị thiếu (2) Chuyển đổi các đặc trưng danh mục thành số (3) Chuẩn hóa dữ liệu
[24]	3	(1) Cân bằng lớp dữ liệu (2) Xử lý các giá trị bị thiếu (3) Trích chọn đặc trưng
[41]	3	(1) Số hóa (2) Chuẩn hóa (3) Trích chọn đặc trưng
[5]	3	(1) Giải quyết vấn đề giá trị bị thiếu (2) Mã hóa biến phân loại (3) Trích chọn đặc trưng
[25]	3	(1) Chuyển đổi loại dữ liệu đối tượng sang định dạng số (2) Loại bỏ trùng lặp dữ liệu (3) Trích chọn đặc trưng
[19]	2	(1) Tiền xử lý dữ liệu văn bản (2) Trích chọn đặc trưng
[38]	2	(1) Xử lý các giá trị bị thiếu (2) Trích chọn đặc trưng
[1, 37, 48]	1	(1) Trích chọn đặc trưng

bước. Thông tin về số lượng các bước tiền xử lý dữ liệu sử dụng trong các nghiên cứu trước đây được tổng hợp trong bảng 1.1. Các bước này được mô tả chi tiết dưới đây.

Dalli [7] (2022) đã Khám phá phương pháp tiền xử lý dữ liệu gồm sáu bước để cải thiện quá trình đào tạo mô hình. Các bước này bao gồm xử lý các giá trị bị thiếu, loại bỏ các giá trị ngoại lai, mã hóa các biến phân loại, chuẩn hóa dữ liệu, giải quyết sự mất cân bằng lớp bằng SMOTE và trích chọn đặc trưng dựa trên mối tương quan cao. Tuy nhiên, việc phụ thuộc vào các đặc điểm có mối tương quan cao để lựa chọn có thể bỏ qua các trường dữ liệu hữu ích khác, cho thấy cần có chiến lược trích chọn đặc điểm toàn diện hơn. phương pháp lấy mẫu tổng hợp thiếu số (SMOTE) đã được triển khai, một chiến lược cũng được áp dụng bởi Tékouabou và cộng sự [43] và Usman-Hamza và cộng sự [45] trong các nghiên cứu của họ. (6) Trích chọn đặc trưng: Do chỉ tập trung vào các đặc trưng có mối tương quan cao nên cách tiếp cận của Dalli có thể vô tình bỏ qua các trường dữ liệu khác có thể góp phần cải thiện hiệu suất dự đoán. Điều này nhấn mạnh tiềm năng của một quá trình trích chọn đặc trưng toàn diện hơn.

Fujo và cộng sự [12] (2022) đã áp dụng một chiến lược tiền xử lý dữ liệu gồm năm bước. Nhóm tác giả xử lý dữ liệu bị thiếu, mã hóa các trường dữ liệu phân loại bằng "label encoding" và "one-hot encoding", chuẩn hóa các giá trị có phương sai cao, thực hiện trích chọn đặc trưng và xử lý mất cân bằng lớp thông qua oversampling. Phương pháp trích xuất đặc trưng của nhóm tác giả sử dụng ma trận tương quan với ngưỡng phương sai trên 0.5. Hồi quy Lasso được sử dụng để loại bỏ các biến không liên quan. Phương pháp này có một số nhược điểm, bao gồm khó khăn trong việc xử lý các đặc trưng tương quan và khó khăn trong việc xử lý mối quan hệ phi tuyến phức tạp. Để giảm thiểu mất cân bằng dữ liệu, nhóm tác giả sử dụng phương pháp oversampling ngẫu nhiên.

Sana và cộng sự [33] (2022) đã áp dụng quá trình tiền xử lý dữ liệu gồm bốn bước, bao gồm: (1) Xử lý các giá trị số bị thiếu bằng cách thay thế bằng số 0. (2) Chuyển đổi từ hạng mục sang số được thực hiện bằng Label Encoder; (3) Biến đổi dữ liệu bao gồm sáu phương pháp, với Weight-of-evidence cho kết quả tốt nhất (4) Trích chọn đặc trưng sử dụng trích chọn đặc trưng không tương quan. Phương pháp trích chọn đặc trưng này tương đối đơn giản để thực hiện, tuy nhiên nó tồn tại nhược điểm trong việc bắt kịp tương tác giữa các đặc trưng, xem xét sự phụ thuộc giữa các đặc trưng và có thể xảy ra overfitting hoặc underfitting.

Jajam và Challa [20] (2023) đã sử dụng ba bước tiền xử lý dữ liệu, bao gồm loại bỏ các bản ghi có giá trị bị thiếu, chuyển đổi các trường dữ liệu phân loại thành số và sử dụng tiền xử lý dựa trên chuẩn hóa Z-score để biến đổi dữ liệu gốc thành định dạng hữu ích. Mặc dù phương pháp chuẩn hóa này hoạt động tốt khi có tri thức trước về biến động điểm và điểm trung bình của bộ phân lớp có sẵn, nhưng nó cũng có một số nhược điểm. Cụ thể, các giá trị ngoại lai có khả năng làm sai lệch quá trình chuẩn hóa và dữ liệu có

phân phối lệch có thể trở nên khó hiểu hơn. Phương pháp này cũng được sử dụng trong [43] và [35].

Lalwani và cộng sự [24] (2022) đã thực hiện ba bước tiền xử lý dữ liệu trong nghiên cứu của họ. Trước tiên, nhóm tác giả chọn dữ liệu phù hợp và cân bằng phân phối lớp sử dụng phân tích phương sai dữ liệu và các kỹ thuật lấy mẫu lại. Tiếp theo, nhóm tác giả loại bỏ các giá trị bị thiếu và các tham số không liên quan. Cuối cùng, thuật toán tìm kiếm hấp dẫn (GSA) được sử dụng để trích chọn đặc trưng. Tuy nhiên, GSA có nhược điểm như tốc độ hội tụ chậm và dễ rơi vào các điểm tối ưu cục bộ.

Bogaert và Delaere [5] (2023) đã tiến hành phương pháp tiền xử lý dữ liệu bao gồm ba bước trong nghiên cứu của họ. Nhóm tác giả đã giải quyết vấn đề giá trị bị thiếu, thực hiện mã hóa biến phân loại và thực hiện trích chọn đặc trưng. Trong trường hợp thiếu giá trị, các tác giả thực hiện dựa trên quy tắc: nếu một biến thể hiện dữ liệu bị thiếu trên 5% thì biến đó sẽ bị loại bỏ; Ngoài ra, đối với các biến có dữ liệu bị thiếu dưới 5%, các kỹ thuật hoàn thiện đa dạng (như hoàn thiện bằng giá trị trung vị hoặc chế độ) được áp dụng. Các biến phân loại được áp dụng mã hóa Dummy để chuyển đổi thành các phiên bản nhị phân. Để chọn ra các đặc trưng quan trọng, các tác giả đã sử dụng điểm Fisher, tập trung vào 20 biến hàng đầu. Tuy nhiên, nhược điểm của phương pháp này nằm ở việc phụ thuộc vào một số biến đã được quy định trước, thiếu cơ sở khoa học vững chắc để xác định số biến hợp lý. Hơn nữa, các biến được ghi điểm theo cặp cùng với biến "churn" và do đó không xem xét được sự tương quan chéo giữa chúng.

Sudharsan và Ganesh [41] (2022) đã thực hiện ba bước tiền xử lý dữ liệu, tập trung vào việc số hóa, chuẩn hóa và trích xuất đặc trưng. Giai đoạn ban đầu liên quan đến chuyển đổi các giá trị chuỗi thành biểu diễn số để thuận tiện cho việc xử lý dữ liệu. Sau đó, nhóm tác giả sử dụng Log Scaling để chuẩn hóa dữ liệu, từ đó nâng cao khả năng so sánh các đặc trưng. Một khía cạnh đặc biệt trong nghiên cứu này là nhóm tác giả tích hợp Brownian Movement (BM) với Butterfly Optimization Algorithm (BOA) để trích xuất đặc trưng. Cách tiếp cận mới này mở rộng phạm vi khám phá của BOA thông qua BM, dẫn đến việc khám phá các đặc trưng bị bỏ qua bởi các phương pháp truyền thống và cuối cùng làm tăng độ chính xác của việc trích xuất. Tuy nhiên, BM-AOA cũng có nhược điểm như tốn thêm chi phí tính toán và nhạy cảm với cài đặt tham số.

Jitendra Maan và Harsh Maan [25] (2023) đã thực hiện ba bước tiền xử lý dữ liệu: chuyển đổi loại dữ liệu đối tượng sang định dạng số, loại bỏ trùng lặp dữ liệu và tiến hành trích chọn đặc trưng đơn giản bằng cách loại trừ các đặc trưng không liên quan.

Hooda và Mittal [19] (2023) đã sử dụng phương pháp tiền xử lý dữ liệu bao gồm hai bước, tiền xử lý dữ liệu văn bản và trích xuất đặc trưng. Nghiên cứu của nhóm tác giả bắt đầu bằng việc biến đổi dữ liệu văn bản sang định dạng số, hợp lý hóa dữ liệu cho các kỹ thuật phân lớp được thực hiện sau đó. Đáng chú ý, Phân tích thành phần chính hạt

nhân (Kernel Principal Component Analysis - KPCA) đã được triển khai để trích xuất các đặc trưng quan trọng, giảm chiều dữ liệu và nắm bắt các biến thể thiết yếu trong bộ dữ liệu. Bên cạnh những ưu điểm của KPCA, phương pháp này vẫn thể hiện những hạn chế như nhu cầu tài nguyên tính toán, overfitting, giảm khả năng diễn giải và nhạy cảm với các giá trị ngoại lai.

Sina Mirabdolbaghi và Amiri [38] (2022) đã tiến hành xử lý các giá trị bị thiếu và tiến hành trích chọn đặc trưng thông qua các phương pháp như PCA, Autoencoders, LDA, T-SNE và XGBoost. Trong đó XGBoost được chứng minh là phương pháp trích chọn đặc trưng tối ưu, tuy nhiên, phương pháp này vẫn tồn tại một số nhược điểm như cần độ chính xác cao trong việc điều chỉnh siêu tham số, chi phí tính toán và vấn đề về khả năng mở rộng cho các bộ dữ liệu lớn.

Ngoài ra, một số nghiên cứu nhất định đã tập trung vào việc áp dụng một bước tiền xử lý dữ liệu duy nhất, cụ thể là trích chọn đặc trưng.

Al-Shourbaji và cộng sự [37] (2022) đã giới thiệu phương pháp ACO-RSA (ant colony optimization - reptile search algorithm) để trích chọn đặc trưng. Được đánh giá trên bảy bộ dữ liệu dự đoán tỷ lệ rời bỏ khách hàng nguồn mở, ACO-RSA vượt trội hơn các thuật toán tối ưu hóa khác. Tuy nhiên, việc kết hợp hai thuật toán có thể làm tăng thời gian tính toán và có thể dẫn đến hiện tượng overfitting.

Abdulsalam và cộng sự [1] (2022) đã đề xuất thuật toán Relief-F cải tiến để trích chọn đặc trưng. Tính phù hợp của thuật toán bị giảm đi đối với các bộ dữ liệu có nhiều đặc trưng, vì việc tính toán khoảng cách theo cặp trở nên tốn kém về mặt tính toán và việc xem xét đặc trưng lân cận bị hạn chế có thể không nắm bắt được các mối quan hệ phức tạp.

Một kỹ thuật khác được sử dụng trong giai đoạn tiền xử lý dữ liệu là Xây dựng đặc trưng mới với nhóm cách đều, được giới thiệu bởi Tianpei Xu và cộng sự (2021) [48]. Tianpei Xu và cộng sự [48] (2021): Giới thiệu Xây dựng đặc trưng mới với đặc trưng Nhóm cách đều nhau để trích chọn đặc trưng. Mặc dù nâng cao độ chính xác và giảm chiều dữ liệu, kỹ thuật này có những nhược điểm, bao gồm mất thông tin, nhạy cảm với các ngoại lai, tính linh hoạt hạn chế và khả năng sai lệch trong kết quả.

Nhận xét về quá trình tiền xử lý dữ liệu trong các nghiên cứu đi trước: Quá trình tiền xử lý dữ liệu có thể được thực hiện qua một số bước như sau: (1) Làm sạch dữ liệu; (2) Xử lý các đặc điểm, bản ghi có giá trị thiếu; (3) Mã hóa các biến phân loại; (4) Biến đổi dữ liệu; (5) Chuẩn hóa dữ liệu; (6) Giải quyết tình trạng mất cân bằng lớp; và (7) trích chọn đặc trưng. Mỗi bước bao gồm các phương pháp có ưu điểm và nhược điểm khác nhau, như đã nêu ở trên. Do đó, việc nghiên cứu kỹ lưỡng các phương pháp này để lựa chọn phương pháp phù hợp nhất cho quá trình tiền xử lý dữ liệu là điều rất cần thiết.

1.4.2. Kỹ thuật học máy để dự đoán hành vi của khách hàng

1.4.2.1. Tổng quan nghiên cứu đi trước về thuật học máy để dự đoán hành vi của khách hàng

Dự đoán hành vi của khách hàng, dù liên quan đến việc rời bỏ hay tần suất mua hàng, đều có điểm chung là cả hai loại hình hành vi này đều có thể được dự đoán dựa vào dữ liệu lịch sử của khách hàng và các kỹ thuật lập mô hình dự đoán để dự đoán các kiểu hành vi. Phần này khảo sát một số kỹ thuật học máy đã được sử dụng để thực hiện công việc đó. Trước hết, luận văn tóm tắt về các kỹ thuật này trong Bảng 1.2. Sau đó, chúng được mô tả cụ thể hơn trong phần này và sau cùng là một số nhận xét được đưa ra sau quá trình khảo sát.

Bảng 1.2. Tổng hợp các phương pháp, thuật toán phân lớp được sử dụng trong một số nghiên cứu cập nhật

Phương pháp	Nguồn	Phương pháp/ thuật toán phân lớp được sử dụng
Thuật toán học máy truyền thống	[19]	Mô hình OKMSVM (One-Class Kernelized Support Vector Machine)
	[28]	SimpleCart, C4.5, RepTree và Random Tree
Học kết hợp	[20]	Blended LR Decision Tree (BLRDT)
	[5]	So sánh các thuật toán phân lớp truyền thống, các nhóm đồng nhất và các nhóm không đồng nhất trên 11 bộ dữ liệu
	[14]	Hợp nhất Logistic Regression (LR), XGBoost (XGB), Random Forest (RF) và Neural Networks (NN)
	[45]	Áp dụng học kết hợp với các mô hình DF (LMT, RF và FT)
	[35]	SVM + CHAID, SVM + C5, SVM + C&R Tree, SVM + Neural Networks và SVM + kNN
	[48]	Học kết hợp dựa trên XgBoost, LR, DT và Naïve Bayes
	[24]	Áp dụng một số thuật toán học máy truyền thống (LR, Naive Bayes, SVM, DT, Extra Tree) và một số thuật toán tổng hợp (RF, Adaboost, XgBoost và CatBoost)
	[38]	Thuật toán LightGBM
	[46]	Xgboost
	[34, 36]	Random Forest
	[43]	RF, Đóng bao, GB, Cây bổ sung (ET) và AdaBoost
Học sâu	[17]	Mô hình AOA-SBLSTM
	[41]	Mô hình S-RNN (Swish Recurrent Neural Network)
	[2]	Mô hình neural network và 4 thuật toán Bayesian, cây C5, CHAID, cây phân loại và hồi quy
	[7]	Mô hình neural network
	[9]	Mô hình CNN
	[12]	Mô hình Deep-BP-ANN
Học sâu và học kết hợp	[33]	8 thuật toán: KNN, Naïve Bayes, LR, RF, DT, GB, FNN và RNN
	[10]	LR, KNN, Cây phân loại và cây hồi quy (CART), RF, SVM, XgBoost, LightGBM và MLP
	[32]	Adaboost, RF, ERT, XgBoost, GBM, đóng bao, xếp chồng, LR, DT, KNN, ANN và CNN
	[1]	Random Forest, Gradient Boosted tree, KNN, Naive Bayes, Kernel Naive Bayes, và Neural Network

a. Thuật toán học máy truyền thống:

Hooda và Mittal [19] (2023) đã đề xuất mô hình OKMSVM (One-Class Kernelized Support Vector Machine) sau khi triển khai thuật toán KPCA để trích xuất đặc trưng đáng tin cậy. Cụ thể, nhóm tác giả đã sử dụng thuật toán tối ưu hóa ALO (Ant Lion optimizer) để chọn siêu tham số tối ưu cho mô hình học máy đề xuất. Mặc dù thuật toán ALO có những ưu điểm, như khả năng khám phá không gian tìm kiếm và tìm kiếm các giải pháp tối ưu, nhưng nó cũng có một số nhược điểm, chẳng hạn như ALO yêu cầu tính toán phức tạp để xác định vị trí mới cho các Ant và Lion trong quá trình tìm kiếm; bên cạnh đó, ALO có thể không đảm bảo độ ổn định cao trong quá trình tìm kiếm. Kết quả của thuật toán có thể thay đổi đáng kể với các lần chạy khác nhau hoặc khi thay đổi các tham số của thuật toán. Cuối cùng, nhóm tác giả so sánh mô hình SVM hai cấp độ lai (HTL-SVM) hiện có với mô hình OKMSVM mới để chứng minh hiệu suất được cải thiện của mô hình đề xuất.

Ruba Obiedat [28] tập trung vào bốn thuật toán DT được sử dụng rộng rãi: SimpleCart, C4.5, RepTree và Random Tree. Việc lựa chọn thuật toán DT được thúc đẩy bởi thực tế là các mô hình kết quả được cấu trúc theo quy tắc IF-THEN, khiến chúng trở nên dễ hiểu đối với những người ra quyết định có chuyên môn kỹ thuật hạn chế, đặc biệt trong các lĩnh vực như ngân hàng và tài chính. Bộ dữ liệu được sử dụng trong nghiên cứu được lấy từ một chiến dịch tiếp thị trực tiếp do một ngân hàng Bồ Đào Nha thực hiện. Để nâng cao hiệu suất phân lớp, nghiên cứu sử dụng kỹ thuật trích chọn đặc trưng dựa trên bộ lọc. Kết quả thu được chỉ ra rằng trong số các thuật toán được xem xét, SimpleCart thể hiện hiệu suất dự đoán tốt nhất.

b. Phương pháp học kết hợp:

Jajam và Challa [20] (2023) đề xuất phương pháp Blended LR Decision Tree (BLRDT) để phát hiện tình trạng rời bỏ. Mặc dù có hiệu quả trong việc đánh giá mức độ rời bỏ của khách hàng nhưng BLRDT cũng có những hạn chế. Có thể cần một khối lượng dữ liệu đáng kể để xác định một cách đáng tin cậy các yếu tố dự báo thiết yếu và xây dựng một mô hình đáng tin cậy. Hơn nữa, sự phức tạp của phương pháp này có thể thách thức việc giải thích và nó có thể nhạy cảm với những thay đổi về dữ liệu hoặc điều kiện kinh doanh, yêu cầu phải hiệu chỉnh lại thường xuyên.

Bogaert và Delaere [5] (2023) đã tiến hành một nghiên cứu điểm chuẩn toàn diện về dự đoán tỷ lệ rời bỏ khách hàng, so sánh các thuật toán phân lớp truyền thống, các nhóm đồng nhất và các nhóm không đồng nhất trên nhiều bộ dữ liệu khác nhau. Họ đã đánh giá 33 bộ phân lớp, trong đó các nhóm không đồng nhất luôn hoạt động tốt hơn các nhóm khác.

Geiler và cộng sự [14] đã thực hiện một cuộc khảo sát toàn diện đi sâu vào các phương pháp được sử dụng trong kỹ thuật lấy mẫu và mô hình dự đoán nhằm mục đích

xác định các mô hình rời bỏ. Nghiên cứu của họ được tổ chức thành ba giai đoạn liên tiếp: Lấy mẫu, Lập mô hình và Đánh giá. Trong giai đoạn lấy mẫu, các nhà nghiên cứu đã khám phá bảy chiến lược được điều chỉnh để giải quyết sự mất cân bằng giữa các lớp, được phân loại là lấy mẫu quá mức, lấy mẫu dưới mức hoặc kết hợp. Ở giai đoạn lập mô hình, nhóm tác giả đánh giá 11 kỹ thuật, bao gồm các phương pháp giám sát, bán giám sát và tập hợp. Nghiên cứu tổng thể của họ đề xuất hợp nhất Logistic Regression (LR), XGBoost (XGB), Random Forest (RF) và Neural Networks (NN) để dự đoán tình trạng rời bỏ. Nhóm tác giả đã tính toán xác suất dự đoán trung bình cho các trường hợp sử dụng hoán vị của các phương pháp này. Các kết quả nhất quán nhấn mạnh tính hiệu quả của phương pháp học kết hợp LR|XGBoost|RF|NN trên các chiến lược lấy mẫu và bộ dữ liệu đa dạng, vượt trội so với các phương pháp thay thế. Tương tự như vậy, nhóm LR|XGBoost|RF đã thể hiện hiệu suất cạnh tranh. Các nhà nghiên cứu ủng hộ cách tiếp cận tổng thể tối ưu tích hợp ba phương pháp này (LR|XGBoost|RF), đặc biệt là không cần lấy mẫu chuyên dụng. Trên cơ sở mỗi bộ dữ liệu, quy trình tổng hợp được đề xuất của họ, LR|XGBoost|RF, luôn đạt được chỉ số AUC cao nhất. Thành tích này vẫn ổn định trên hầu hết các bộ dữ liệu, tiến gần đến điểm chuẩn tối ưu. Tóm lại, khung phương pháp của họ nhấn mạnh việc triển khai thực tế nhóm LR|XGBoost|RF mà không cần lấy mẫu bổ sung để phân tích hiệu quả các bộ dữ liệu mới thể hiện các đặc điểm giống như hành vi rời bỏ.

Usman-Hamza và cộng sự [45] (2022) đã phát triển mô hình rừng quyết định thông minh (DF) để Dự đoán tỷ lệ rời bỏ khách hàng trong ngành viễn thông. Nhóm tác giả đã đánh giá tính hiệu quả của các mô hình DF (LMT, RF và FT) được nâng cấp dựa trên phương pháp bỏ phiếu mềm có trọng số và xếp chồng có trọng số, cũng như các mô hình LMT (Logistic Model Tree), RF và Functional Trees (FT). Các mô hình DF đề xuất đã được kiểm tra kỹ lưỡng bằng cách sử dụng bộ dữ liệu dự đoán tỷ lệ rời bỏ khách hàng viễn thông tiêu chuẩn đã được công bố rộng rãi. Các mô hình DF được đề xuất đã phân biệt hiệu quả những người tiêu dùng đang rời bỏ với những người tiêu dùng không rời bỏ, đặc biệt là trong trường hợp mất cân bằng lớp. Hơn nữa, kết quả so sánh đã chứng minh rằng các mô hình DF được đề xuất mang lại hiệu suất dự đoán được cải thiện và các giải pháp tối ưu để dự đoán tỷ lệ rời bỏ khách hàng trong ngành viễn thông so với các phương pháp dự đoán tỷ lệ rời bỏ khách hàng dựa trên máy học cơ bản và hiện có như K-Nearest Neighbors (KNN), Naive Bayes và Decision Stump.

Shabankareh và cộng sự [35] (2022) đã áp dụng các kỹ thuật xếp chồng để dự đoán tỷ lệ rời bỏ khách hàng trong lĩnh vực viễn thông. Họ đã đánh giá các tổ hợp thuật toán, bao gồm Máy vectơ hỗ trợ (SVM) được ghép nối với CHAID (chi-square automatic interaction detection), SVM với C5, SVM với C&R Tree, SVM với Neural Networks (NET) và SVM với k-Láng giềng gần nhất (KNN). Nghiên cứu của họ đã chứng minh rằng kết quả tốt nhất đạt được thông qua việc kết hợp SVM và CHAID.

Tianpei Xu và cộng sự [48] đã giới thiệu một hệ thống dự đoán tỷ lệ rời bỏ khách hàng khai thác các kỹ thuật học kết hợp, đặc biệt là sử dụng các mô hình xếp chồng và bỏ phiếu mềm. Bằng cách tích hợp các thuật toán học máy như XgBoost, LR, DT và Naïve Bayes, nhóm tác giả đã xây dựng mô hình xếp chồng hai cấp độ. Đầu ra cấp hai của mô hình này được sử dụng cho bỏ phiếu mềm. Phát hiện của họ cho thấy tính hiệu quả của phương pháp tiếp cận của họ so với các hệ thống nhận dạng rời bỏ đã được thiết lập. Tuy nhiên, nghiên cứu này tồn tại một hạn chế liên quan đến việc bỏ sót giai đoạn trích chọn đặc trưng trong quá trình phát triển mô hình.

Lalwani và cộng sự [24] (2022) đã áp dụng một số mô hình dự đoán phổ biến như LR, Naive Bayes, SVM, RF, DT, Extra Tree, Adaboost, XgBoost và CatBoost. Nhóm tác giả sử dụng kiểm thử chéo K-Fold trên tập huấn luyện để điều chỉnh siêu tham số và ngăn chặn việc overfitting. Kết quả chỉ ra rằng bộ phân lớp Adaboost và XgBoost hoạt động tốt hơn phương pháp hiện có. Tuy nhiên, cả hai mẫu Adaboost và XgBoost đều có hạn chế là dễ xảy ra hiện tượng overfitting.

Sina Mirabdolbaghi và Amiri [38] (2022) tập trung vào dự đoán tỷ lệ rời bỏ bằng cách sử dụng thuật toán LightGBM với các siêu tham số được điều chỉnh bằng cách sử dụng tối ưu hóa siêu tham số Bayesian (BO-LightGBM) và genetic optimization algorithms (GO-LightGBM). Các mô hình này cho thấy hiệu suất vượt trội so với một số thuật toán khác, chẳng hạn như Cây quyết định, RF, SVM, LR, XgBoost, LightGBM và Adaboost. Tuy nhiên, cả BO-LightGBM và GO-LightGBM đều có những hạn chế. Các phương pháp này yêu cầu nhiều tài nguyên và thời gian tính toán hơn các phương pháp điều chỉnh siêu tham số thay thế. Hơn nữa, bản chất xác suất của BO-LightGBM có thể dẫn đến sự hội tụ dưới mức tối ưu do kích thước mẫu và các phân phối trước đó. GO-LightGBM cũng có thể bị hội tụ sớm, hạn chế việc khám phá không gian tìm kiếm một cách hiệu quả.

Wang, W và cộng sự [46] (2023) đã giới thiệu mô hình dự đoán dựa trên XGBoost để dự báo hành vi mua hàng của người dùng. Cách tiếp cận của nhóm tác giả bao gồm một mô hình giá trị người dùng có tên LDTD, sử dụng các kỹ thuật tổng hợp đa đặc trưng để phân biệt các loại người dùng bằng cách sử dụng dữ liệu tài khoản người dùng có sẵn. Thông qua phản ứng tổng hợp hành vi đa đặc trưng, một đặc trưng thể người dùng nắm bắt các mẫu hành vi đã được tạo. Mô hình tầm quan trọng của đặc trưng XGBoost đã xác định đặc trưng có ảnh hưởng nhất, tạo thành nền tảng cho mô hình dự đoán của họ. đặc trưng này sau đó được tích hợp với các trường dữ liệu người dùng khác trong mô hình XgBoost để đưa ra dự đoán chính xác. Để giải quyết sự mất cân bằng cực độ của lớp, nhóm tác giả đã sử dụng phương pháp lấy mẫu dưới ClusterCentroids, nâng cao độ chính xác của XGB. Các đánh giá so sánh với các mô hình được thiết lập tốt, chẳng hạn như KNN, SVM, RF và BPNN, đã chứng minh hiệu quả của mô hình XgBoost được đề xuất

của họ, đạt được các số liệu có độ chính xác vượt trội, bao gồm độ chính xác 0,9761, điểm F1 là 0,9763 và giá trị AUC là 0,9768. Mô hình này đã giải quyết một cách khéo léo các thách thức về trích chọn đặc trưng và dữ liệu không cân bằng, dẫn đến độ chính xác và độ ổn định cao hơn trong việc dự đoán hành vi mua hàng của người dùng.

Xu Jing và cộng sự [47] (2020) đã đề xuất mô hình xếp chồng SE dựa trên phản ứng tổng hợp thông tin và học kết hợp để dự đoán hành vi mua hàng của người dùng. Để ngăn mô hình bị overfitting, nâng cao độ chính xác và giảm thời gian đào tạo, nghiên cứu này sử dụng SA-EFS để trích chọn đặc trưng. Nó xác nhận rằng tập huấn luyện phù hợp với tập kiểm tra bằng cách đảm bảo sự phân bố và mối tương quan của chúng nhất quán, do đó tránh được tình trạng dư thừa đặc trưng. Sau khi sử dụng thành công phương pháp trích chọn đặc điểm tổng hợp để sàng lọc các yếu tố liên quan đến việc mua hàng, bài viết này đã sử dụng thuật toán xếp chồng để dự đoán hành vi mua hàng của người dùng. Mô hình đã được tối ưu hóa bằng cách chọn mười loại mô hình khác nhau làm người học cơ sở và sửa đổi các tham số liên quan cụ thể cho chúng. Điểm F1 của mô hình nhiệt hạch được xây dựng trong bài báo này đạt 98,40

Tékouabou và cộng sự [43] (2022) đề cập đến việc dự đoán tỷ lệ rời bỏ khách hàng bằng cách sử dụng bộ dữ liệu không cân bằng. Họ đã sử dụng các thuật toán học kết hợp như RF, Đóng bao, Tăng cường độ dốc (GB), Cây bổ sung (ET) và AdaBoost, đồng thời đối chiếu hiệu suất của chúng với các thuật toán học máy truyền thống bao gồm KNN, SVM, DT, LR, Artificial Neural Network (ANN) và Naive Bayes. Trong số các thuật toán này, RF được xác định là một trong những thuật toán hiệu quả nhất để dự đoán các vấn đề phân lớp rời bỏ khách hàng.

Trong học kết hợp, Rừng ngẫu nhiên (RF) được công nhận là thuật toán hiệu suất cao phù hợp với nhiều bài toán. Shivam Sharma và cộng sự [36] (2020) đã phát triển một mô hình dự đoán để dự báo các quyết định mua hàng theo ý định mua sắm trực tuyến. Nhóm tác giả đã đánh giá tỉ mỉ các Thuật toán học máy được giám sát khác nhau, bao gồm SVM, RF, LR và KNN. Bằng cách triển khai từng thuật toán một cách độc lập, nhóm tác giả đã tạo ra các ma trận nhầm lẫn riêng biệt. Các kết quả đặc biệt nêu bật hiệu suất vượt trội của RF. Phát hiện này đã được chứng thực bởi G. Sang và cộng sự [34] (2022), nhóm tác giả cũng công nhận RF là thuật toán hiệu quả nhất để dự đoán chính xác các quyết định mua hàng, đặc biệt là sau khi áp dụng kỹ thuật lấy mẫu quá mức.

c. Học sâu:

Haridasan và cộng sự [17] (2023) đã đề xuất một cách tiếp cận sáng tạo bằng cách giới thiệu mô hình AOA-SBLSTM. Mô hình này kết hợp thuật toán AOA (arithmetic optimization algorithm) với mô hình bộ nhớ ngắn hạn dài hai chiều (SBLSTM) xếp chồng lên nhau. AOA được khai thác để tinh chỉnh các siêu tham số, trong khi SBLSTM được sử dụng để phân lớp dữ liệu rời bỏ khách hàng. Mô hình AOA-SBLSTM cho thấy

hiệu suất vượt trội so với các kỹ thuật hiện có, mặc dù bản thân AOA cũng có những hạn chế, bao gồm tốc độ hội tụ chậm, thiếu sự đảm bảo về các giải pháp tối ưu và dễ bị overfitting do độ phức tạp của siêu tham số.

Sudharsan và Ganesh [41] (2022) đã đề xuất một khuôn khổ mới để dự đoán tỷ lệ rời bỏ khách hàng bằng mô hình học sâu, cụ thể là S-RNN (Swish Recurrent Neural Network). Nhóm tác giả đã kết hợp Chức năng AF (Swish Activation vào RNN (Recurrent Neural Network)) để khắc phục vấn đề vanishing gradient liên quan đến chức năng sigmoid. Mặc dù tính hiệu quả đã được chứng minh trong nghiên cứu này nhưng S-RNN vẫn tồn tại một số nhược điểm: (1) S-RNN có thể không hoạt động tốt với các bộ dữ liệu nhỏ hoặc mất cân bằng, vì nó gặp khó khăn trong việc tìm ra các mẫu và xác định các yếu tố gián đoạn tiềm năng trong các bộ dữ liệu đó, dẫn đến hiệu suất kém. (2) S-RNN có thể yêu cầu một bộ dữ liệu lớn để đào tạo hiệu quả. (3) S-RNN có thể không hoạt động tốt khi số lượng đặc trưng quá lớn vì có thể dẫn đến tình trạng overfitting. (4) S-RNN có thể tốn kém về mặt tính toán và yêu cầu tài nguyên tính toán đáng kể.

Al-Najjar và cộng sự [2] (2022) đã chọn năm mô hình dự đoán máy học, bao gồm mạng Bayesian, cây C5, CHAID (chi-square automatic interaction detection), cây phân loại và hồi quy (CR) và neural network để dự đoán tỷ lệ rời bỏ. Kết quả đã chứng minh rằng, khi so sánh với ba mô hình còn lại, mô hình học máy cây C5 hoạt động tốt nhất. Nhìn chung, mặc dù mô hình cây C5 cho thấy hiệu suất tốt trong nghiên cứu này nhưng nó có thể không phải là lựa chọn tối ưu cho tất cả các loại dữ liệu và có thể cần điều chỉnh cẩn thận để đạt được kết quả tối ưu. Ví dụ, việc xử lý các ngoại lai một cách cẩn thận là cần thiết vì mô hình cây C5 rất nhạy cảm với nhiễu và các ngoại lai, điều này có thể dẫn đến dự đoán overfitting và không chính xác.

Dalli [7] (2022) đã nghiên cứu ảnh hưởng của các cấu hình siêu tham số khác nhau trong các mô hình học sâu và đưa ra ba phát hiện chính: (1) Hàm kích hoạt Relu đã được sử dụng thành công trong các lớp ẩn của mạng sâu. (2) Hàm sigmoid cải thiện đáng kể hiệu suất của mô hình mạng lưới thần kinh. (3) Hiệu suất của mô hình được cải thiện khi kích thước lô trong mô hình nhỏ hơn kích thước của bộ dữ liệu thử nghiệm. Về độ chính xác, trình tối ưu hóa RemsProp vượt trội hơn các thuật toán khác như stochastic gradient descent (SGD), Adadelta, Adam, AdaGrad và AdaMax.

Elgohary và cộng sự [9] (2023) đã giới thiệu một phương pháp cải tiến bằng cách giới thiệu dịch vụ dự đoán tỷ lệ rời bỏ khách hàng tự động dựa trên thuật toán học sâu Convolutional Neural Network (CNN). Phương pháp của nhóm tác giả bao gồm ghi nhãn dữ liệu, ứng dụng khung CNN để dự đoán tỷ lệ rời bỏ và trình diễn đào tạo mô hình tự động bằng cách sử dụng dữ liệu khách hàng thực. Nghiên cứu đã giới thiệu việc điều chỉnh tự động các siêu tham số CNN để đảm bảo lựa chọn mô hình tối ưu.

Fujo và cộng sự [12] (2022) đã khuyến nghị sử dụng mô hình Deep-BP-ANN để

dự đoán tỷ lệ rời bỏ. Mô hình này đã được cải tiến bằng cách triển khai các kỹ thuật early stopping để hạn chế việc đào tạo vào thời điểm thích hợp và ngăn chặn tình trạng overfitting. Mô hình đề xuất cho thấy hiệu suất vượt trội so với các kỹ thuật học máy thông thường như XgBoost, LR, Naive Bayes và KNN. Hơn nữa, trong cùng một bộ dữ liệu, mô hình Deep-BP-ANN thể hiện độ chính xác cao hơn các phương pháp học sâu khác sử dụng xác thực loại trừ hoặc kiểm thử chéo 10 lần (CV). Tuy nhiên, mô hình đề xuất có một số hạn chế nhất định: (1) Nó yêu cầu nguồn lực tính toán đáng kể. (2) Cần một lượng dữ liệu đào tạo đáng kể, vì Deep-BP-ANN dựa vào một lượng dữ liệu đáng kể để đào tạo hiệu quả. (3) Mô hình dễ bị ảnh hưởng bởi cực tiểu cục bộ. Thuật toán tối ưu hóa được sử dụng trong Deep-BP-ANN không tránh khỏi các trường hợp hội tụ đến mức cực tiểu cục bộ, có khả năng mang lại kết quả dưới mức tối ưu.

d. Học sâu và học kết hợp

Một số nhóm tác giả khác sử dụng cả học sâu và học kết hợp trong nghiên cứu của họ. Chẳng hạn, Sana và cộng sự [33] (2022) đã giải quyết vấn đề dự đoán tỷ lệ rời bỏ khách hàng bằng cách sử dụng 8 thuật toán: KNN, Naïve Bayes (NB), LR, RF, DT, Gradient Boosting (GB), Feed-forward Neural Networks (FNN) và Recurrent Neural Networks (RNN). Việc điều chỉnh siêu tham số được thực hiện cho từng bộ phân lớp bằng kỹ thuật tìm kiếm lưới, một phương pháp được sử dụng rộng rãi để tối ưu hóa siêu tham số trong các mô hình học máy.

Elyusufi và cộng sự [10] nhằm mục đích dự đoán chính xác những khách hàng có xu hướng ở lại với ngân hàng và tôn trọng các cam kết của họ Sau khi áp dụng ba bước tiền xử lý bao gồm lấy mẫu lại dữ liệu, chia tỷ lệ và điều chỉnh siêu tham số. Nhóm tác giả đã so sánh kết quả của việc áp dụng tám thuật toán học máy: LR, KNN, Cây phân loại và cây hồi quy (CART), RF, SVM, XgBoost, LightGBM và Multi-Layer Perceptron (MLP). Sau khi đánh giá các mô hình này, họ cũng quan sát thấy mô hình RF đạt được điểm chính xác cao nhất.

Saha và cộng sự [32] (2023) đã đề xuất nhiều chiến lược học tập khác nhau để xây dựng mô hình dự đoán tỷ lệ rời bỏ. Họ đã thử nghiệm các kỹ thuật học kết hợp (Adaboost, RF, ERT, XgBoost, tăng cường độ dốc (GBM), đóng bao và xếp chồng), các kỹ thuật phân lớp truyền thống (LR, DT, KNN và mạng thần kinh nhân tạo (ANN)), và kỹ thuật CNN học sâu để chọn mô hình tốt nhất cho việc dự đoán tỷ lệ rời bỏ khách hàng. CNN và ANN hoạt động tốt hơn các kỹ thuật khác trên cả hai bộ dữ liệu được sử dụng trong nghiên cứu này.

Bên cạnh đó, một số tác giả cũng đã sử dụng đa dạng các dạng thuật toán khác nhau để dự đoán sự trung thành của khách hàng đối với chuỗi siêu thị dựa trên tần suất mua hàng, chẳng hạn: [1]. Để dự đoán sự trung thành của khách hàng, các thuật toán Random Forest, Gradient Boosted tree, KNN, Naive Bayes, Kernel Naive Bayes, và

Neural Network đã được sử dụng. Kết quả cho thấy các mô hình dựa trên ANN đề xuất có thể dự đoán chính xác 60% và 72% tần suất mua hàng của khách hàng.

Nhận xét về kỹ thuật học máy được sử dụng trong dự đoán hành vi của khách hàng và khoảng trống nghiên cứu: Các nghiên cứu được đề cập ở trên đã sử dụng nhiều thuật toán học máy truyền thống và phương pháp học kết hợp để dự đoán hành vi của khách hàng. Một số thuật toán học kết hợp được áp dụng phổ biến và mang lại hiệu quả tốt là RF, XGBoost, LightGBM, Adaboost và Catboost. Bên cạnh đó, một số nghiên cứu cũng đã sử dụng kết hợp các thuật toán học sâu vào quá trình dự đoán này và các tác giả đã chứng minh được hiệu quả của nó trong dự đoán hành vi của khách hàng. Một kết luận quan trọng khác được rút ra từ quá trình khảo sát là chưa có nghiên cứu nào dự đoán hành vi khách hàng sử dụng phương pháp học kết hợp với các mô hình học cơ sở là sự kết hợp đồng thời các thuật toán tăng cường, đóng bao và học sâu với nhau.

1.4.2.2. Giới thiệu một số thuật toán/phương pháp phân lớp có hiệu suất tốt và được đưa vào sử dụng trong luận văn

a. Thuật toán học máy truyền thống - Logistic Regression:

Phân lớp Logistic Regression là một kỹ thuật được sử dụng để phân lớp dữ liệu bằng cách sử dụng mặt phẳng. Kỹ thuật này được áp dụng khi các điểm dữ liệu có thể được tách rời tuyến tính. Do đó, Logistic Regression thường được áp dụng cho các vấn đề phân lớp nhị phân [40].

Thuật toán này có thể tổng quát hóa cho bài toán phân loại (nhị phân) bằng cách thực hiện hai thay đổi so với bài toán hồi quy [27] được trình bày sau đây:

Trước tiên, ta thay thế phân phối Gaussian cho y bằng phân phối Bernoulli, phù hợp hơn trong trường hợp phân lớp nhị phân, $y \in \{0, 1\}$. Điều đó có nghĩa là cần sử dụng

$$p(y|x, w) = \text{Ber}(y|\mu(x)) \quad (1.1)$$

với $\mu(x) = E[y|x] = p(y = 1|x)$.

Thứ hai, cần tính tổ hợp tuyến tính của các đầu vào, sau đó truyền qua một hàm đảm bảo $0 \leq \mu(x) \leq 1$ bằng cách định nghĩa

$$\mu(x) = \sigma(w^T x) \quad (1.2)$$

trong đó $\sigma(\eta)$ đề cập đến hàm sigmoid, còn được gọi là hàm logistic hoặc hàm logit. Thuật toán Logistic Regression dựa trên giả định rằng xác suất $p(y = 1|x)$ có thể được biểu diễn dưới dạng hàm tuyến tính của đầu vào x , ký hiệu là $w^T x$, trong đó w là vector trọng số và x là vector đầu vào. Tuy nhiên, để đảm bảo xác suất nằm trong khoảng từ 0 đến 1, ta sử dụng hàm sigmoid (hay hàm logistic) để ánh xạ giá trị tuyến tính thành giá

trị xác suất. Hàm sigmoid được định nghĩa như sau:

$$\sigma(\eta) = \frac{1}{1 + \exp(-\eta)} = \frac{e^\eta}{e^\eta + 1} \quad (1.3)$$

Thuật ngữ "sigmoid" có nghĩa là hình dạng dạng S. Nó cũng được gọi là hàm nén vì nó ánh xạ toàn bộ trục số thực thành $[0, 1]$, điều này là cần thiết để đầu ra có thể được hiểu là một xác suất. Tổng hợp hai bước này, ta có:

$$p(y|x, w) = \text{Ber}(y|\sigma(w^T x)) \quad (1.4)$$

Thuật toán này được gọi là hồi quy logistic do sự tương đồng với hồi quy tuyến tính (mặc dù nó là một hình thức phân loại, không phải hồi quy).

b. Thuật toán đóng bao: Random Forest:

Thuật toán này được ra đời vào năm 2001, là một sự thay đổi đáng kể của bagging, xây dựng một tập hợp lớn các cây tương quan thấp và lấy trung bình kết quả của chúng. Trong nhiều bài toán, hiệu suất của Random Forests rất tương tự với thuật toán tăng cường nhưng Random Forests dễ huấn luyện và điều chỉnh hơn. Do đó, Random Forests được ưa chuộng và được triển khai trong nhiều gói phần mềm khác nhau [18].

Ý tưởng trong Random Forests (Thuật toán 1.1) là cải thiện việc giảm phương sai của bagging bằng cách giảm tương quan giữa các cây, mà không làm tăng phương sai quá nhiều. Điều này được thực hiện trong quá trình phát triển cây thông qua việc chọn ngẫu nhiên các biến đầu vào.

Thuật toán 1.1 Random Forests với bài toán Phân Lớp

1: Với $b = 1$ đến B :

(a) Rút một mẫu bootstrap Z^* có kích thước N từ dữ liệu huấn luyện.

(b) Xây dựng cây Random Forests T_b dựa trên dữ liệu bootstrap bằng cách lặp lại các bước sau cho mỗi nút cuối của cây, cho đến khi đạt được kích thước nút tối thiểu $n_{\min}$.

- i. Chọn ngẫu nhiên m biến từ p biến.
- ii. Chọn biến/chỉ mục chia tốt nhất trong m biến.
- iii. Chia nút thành hai nút con.

2: Đầu ra tập hợp các cây $\{T_b\}_{b=1}^B$. Để dự đoán cho một điểm mới x :

Cho $\hat{C}_b(x)$ là dự đoán lớp của cây Random Forests thứ b . Khi đó $\hat{C}_{B_{\text{rf}}}(x) =$ phương pháp bình chọn đa số $\{\hat{C}_b(x)\}_{b=1}^B$.

c. Thuật toán tăng cường: Adaboost, XGBoost, Catboost, LightGBM:

Thuật toán tăng cường (Boosting) ra đời vào năm 1997 với mục đích thiết kế ban đầu phục vụ cho các bài toán phân lớp. Động lực cho các thuật toán tăng cường là một quy trình kết hợp kết quả đầu ra của nhiều bộ phân loại "yếu" để tạo ra một phân loại kết

hợp mạnh mẽ hơn [18].

Thuật toán Adaboost: Adaboost là thuật toán tăng cường phổ biến nhất và được đề xuất bởi Freund và Schapire (1997). Thuật toán này còn có tên gọi khác là "AdaBoost.M1". Xem xét một bài toán hai lớp, với biến kết quả được mã hóa là $Y \in \{-1, 1\}$ như sau: Cho một vector các biến dự báo X , một bộ phân loại $G(X)$ tạo ra một dự đoán có giá trị thuộc tập $\{-1, 1\}$. Tỷ lệ lỗi trên mẫu huấn luyện được tính bằng công thức [18]:

$$\text{err} = \frac{1}{N} \sum_{i=1}^N I(y_i \neq G(x_i)), \quad (1.5)$$

và tỷ lệ lỗi kỳ vọng trên các dự đoán tương lai được tính bằng công thức: $EXYI(Y \neq G(X))$.

Dự đoán từ tất cả các bộ phân loại được kết hợp thông qua một cuộc bỏ phiếu có trọng số để tạo ra dự đoán cuối cùng:

$$G(x) = \text{sign} \left(\sum_{m=1}^M \alpha_m G_m(x) \right) \quad (1.6)$$

Ở đây, $\alpha_1, \alpha_2, \dots, \alpha_M$ được tính toán bởi thuật toán boosting và trọng số đóng góp cho mỗi $G_m(x)$. Hiệu ứng của chúng là tăng sự ảnh hưởng cho các bộ phân loại chính xác hơn trong chuỗi.

Các sửa đổi dữ liệu ở mỗi bước boosting bao gồm việc áp dụng trọng số $w_1, w_2, \dots, w_N$ cho mỗi quan sát huấn luyện $(x_i, y_i), i = 1, 2, \dots, N$. Ban đầu, tất cả các trọng số được đặt là $w_i = \frac{1}{N}$, để bước đầu tiên đơn giản là huấn luyện bộ phân loại trên dữ liệu theo cách thông thường. Đối với mỗi lần lặp tiếp theo $m = 2, 3, \dots, M$, trọng số các quan sát được sửa đổi riêng lẻ và thuật toán phân loại được áp dụng lại trên các quan sát có trọng số. Tại bước m , các quan sát bị phân loại sai bởi bộ phân loại $G_{m-1}(x)$ tạo ra ở bước trước đó sẽ có trọng số tăng lên, trong khi trọng số giảm đối với những quan sát được phân loại đúng.

Thuật toán 1.2 hiển thị chi tiết của thuật toán AdaBoost.M1. Bộ phân loại hiện tại $G_m(x)$ được tạo ra trên các quan sát có trọng số tại dòng 2a. Tỷ lệ lỗi có trọng số kết quả được tính toán tại dòng 2b. Dòng 2c tính toán trọng số α_m được gán cho $G_m(x)$ trong việc tạo ra bộ phân loại cuối cùng $G(x)$ (dòng 3). Trọng số cá nhân của mỗi quan sát được cập nhật cho lần lặp tiếp theo tại dòng 2d. Các quan sát được phân loại sai bởi $G_m(x)$ có trọng số được tỷ lệ bởi hệ số $\exp(\alpha_m)$, tăng sự ảnh hưởng tương đối của chúng đối với việc tạo ra bộ phân loại tiếp theo $G_{m+1}(x)$ trong chuỗi [18].

Thuật toán 1.2 AdaBoost.M1 [18]

-
- 1: Khởi tạo trọng số quan sát $w_i = \frac{1}{N}$, $i = 1, 2, \dots, N$.
 - 2: Với $m = 1$ đến M
 - (a) Tìm bộ phân loại $G_m(x)$ cho dữ liệu huấn luyện sử dụng trọng số w_i .
 - (b) Tính toán $err_m = \frac{\sum_{i=1}^N w_i \cdot I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i}$.
 - (c) Tính toán $\alpha_m = \log\left(\frac{1-err_m}{err_m}\right)$.
 - (d) Cập nhật $w_i \leftarrow w_i \cdot \exp(\alpha_m \cdot I(y_i \neq G_m(x_i)))$, $i = 1, 2, \dots, N$.
 - 3: Đầu ra $G(x) = \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right)$.
-

Thuật toán XGBoost: XGBoost (Extreme Gradient Boosting) là một phương pháp học máy được áp dụng trong cây quyết định dựa trên kỹ thuật Gradient Boosting. XGBoost xây dựng các cây quyết định ngắn và quá trình xây dựng mô hình được thực hiện theo cách lặp đi lặp lại. Mỗi cây trong XGBoost được gọi là weak learner (còn được gọi là các "nhân tố yếu") do tính chất thiên vị của nó [11].

Thuật toán XGBoost bắt đầu bằng việc xây dựng một cây quyết định cơ bản đầu tiên với hiệu suất kém. Sau đó, nó tiếp tục xây dựng các cây khác, được huấn luyện để dự đoán những gì mà cây đầu tiên, một weak learner không thể làm được. Quá trình này được thực hiện tuần tự, tạo ra các weak learner tiếp theo, mỗi người học chỉnh sửa cây trước đó trước khi đáp ứng các điều kiện dừng, ví dụ như số lượng cây (bộ ước tính) được xác định trước. XGBoost có một số lợi thế đi kèm. Đầu tiên, nó có tốc độ huấn luyện nhanh, giúp tiết kiệm thời gian trong quá trình xây dựng mô hình. Thứ hai, XGBoost có khả năng được song song hóa hoặc phân phối trên các cụm máy tính, cho phép xử lý hiệu quả trên dữ liệu lớn [11].

Thuật toán XGBoost được triển khai theo các bước như sau:

Bước 1: Khởi tạo mô hình: Sử dụng một lớp cơ sở và lấy đầu ra đầu tiên làm biến mục tiêu.

Bước 2: Tính toán lỗi hoặc Residual (R_1) bằng cách sử dụng một hàm mất mát.

Bước 3: Xây dựng cây quyết định đầu tiên bằng cách sử dụng đặc trưng và R_1 làm biến mục tiêu. Sau khi có dự đoán từ cây, tính toán Residual mới R_2 sao cho $R_2 < R_1$.

Bước 4: Tính toán kết quả cuối cùng bằng cách Kết hợp phân lớp cơ sở và các cây quyết định tuần tự. Tuy nhiên, việc kết hợp trực tiếp cây quyết định với mô hình cơ sở có thể gây overfitting. Do đó, tốc độ học được áp dụng thông qua công thức:

$$y(x) = \text{Base}(x) + \alpha \text{OT}(1)(x) \quad (1.7)$$

Trong đó α là tốc độ học.

Bước 5: Xét $y(x)$: Nếu $y(x)$ khác đáng kể với đầu ra thực tế, thêm một cây khác

dựa trên các đặc trưng đầu vào và $R2$ làm biến mục tiêu.

Giả sử có n cây quyết định, công thức cho đầu ra cuối cùng là:

$$h(x) = h_0(x) + \sum_{i=1}^n \alpha_i h_i(x) \quad (1.8)$$

Trong đó: $h_0(x)$ là phân lớp cơ sở và $h_i(x)$ là cây quyết định thứ i .

Thuật toán Catboost: CatBoost là một thư viện mã nguồn mở được thực hiện dựa trên gradient boosting, sử dụng cây quyết định nhị phân làm các dự đoán cơ sở. Các cây quyết định được xây dựng bằng cách phân chia không gian đặc trưng thành các vùng không giao nhau dựa trên giá trị của một số trường dữ liệu phân chia. Các vùng cuối cùng của cây được gán một giá trị ước lượng của mục tiêu trong vùng đó [30].

Đối với phân lớp nhị phân, hàm logloss của thuật toán Catboost được xác định như sau [6]:

$$\text{Logloss} = - \frac{\sum_{i=1}^N w_i (c_i \log(p_i) + (1 - c_i) \log(1 - p_i))}{\sum_{i=1}^N w_i} \quad (1.9)$$

Trong công thức 1.9:

- N là số lượng mẫu trong tập dữ liệu.
- w_i là trọng số của mẫu thứ i .
- c_i là nhãn thực tế của mẫu thứ i ($c_i = 0$ hoặc $c_i = 1$).
- p_i là dự đoán xác suất của mô hình cho mẫu thứ i thuộc vào lớp positive ($0 \leq p_i \leq 1$).

Thuật toán Catboost cho bài toán phân lớp được triển khai cụ thể như sau:

Bước 1: Khởi tạo dự đoán:

- Dự đoán ban đầu được tính bằng logarit của xác suất lớp (log odds).
- Đối với bài toán phân lớp đa lớp, dự đoán ban đầu cho lớp k được tính bằng công thức:

$$\text{Initial Prediction}_k(x) = \log \left(\frac{P(y = k)}{\sum_{i=1}^K P(y = i)} \right) \quad (1.10)$$

Trong đó, $P(y = k)$ là xác suất tiên nghiệm của lớp k và K là tổng số lớp.

Bước 2: Tính gradient và hessian:

- Gradient và hessian được tính dựa trên hàm mất mát sử dụng (ví dụ: log-loss).

- Đối với bài toán phân lớp đa lớp với hàm mất mát log-loss, gradient và hessian cho mẫu dữ liệu (x, y) và lớp k được tính bằng công thức:

$$\text{Gradient}_k(x) = -\frac{\partial \text{Log-Loss}}{\partial \text{Initial Prediction}_k(x)} \quad (1.11)$$

$$\text{Hessian}_k(x) = \frac{\partial^2 \text{Log-Loss}}{\partial (\text{Initial Prediction}_k(x))^2} \quad (1.12)$$

Trong đó, Log-Loss là hàm mất mát log-loss và $\frac{\partial}{\partial \text{Initial Prediction}_k(x)}$ là đạo hàm riêng theo dự đoán ban đầu cho lớp k .

Bước 3: Xây dựng cây:

- CatBoost xây dựng một tập hợp các cây quyết định bằng cách sử dụng gradient boosting.

- Mỗi cây được xây dựng bằng cách chia tách dữ liệu dựa trên giá trị của các đặc trưng để tối thiểu hóa hàm mất mát. Các cây được xây dựng theo cách cộng dồn, trong đó cây mới cố gắng sửa các sai số của tập hợp cây trước đó.

Bước 4: Cập nhật dự đoán:

- Dự đoán được cập nhật bằng cách thêm dự đoán của cây mới vào tập hợp cây trước đó.

- Công thức cập nhật cho dự đoán sau khi thêm cây mới là:

$$\text{Updated Prediction}_k(x) = \text{Previous Prediction}_k(x) + \eta \cdot \text{Tree Prediction}_k(x) \quad (1.13)$$

Trong đó:

+ η (eta) là tỷ lệ học tập

+ $\text{Previous Prediction}_k(x)$ là dự đoán trước đó cho lớp k

+ $\text{Tree Prediction}_k(x)$ là dự đoán của cây mới cho mẫu dữ liệu x và lớp k .

Thuật toán LighGBM: LightGBM là một thư viện mã nguồn mở và một thuật toán gradient boosting decision tree hiệu suất cao. Nó được phát triển bởi nhóm nghiên cứu tại Microsoft Research và đã trở thành một trong những công cụ phổ biến nhất trong lĩnh vực học máy và khoa học dữ liệu.

LightGBM được thiết kế để giải quyết vấn đề hiệu suất và khả năng mở rộng của các phiên bản gradient boosting decision tree truyền thống như XGBoost và pGBRT. Gradient boosting decision tree là một thuật toán học máy mạnh mẽ và được sử dụng rộng rãi vì khả năng chính xác và khả năng giải thích dễ hiểu. [21]. Các bước thực hiện thuật toán LighGBM bao gồm:

Bước 1: Khởi tạo dự đoán:

- Dự đoán ban đầu được tính bằng logarithm của tỷ lệ giá trị chắc chắn (odds ratio).
- Đối với phân lớp nhị phân, dự đoán ban đầu cho lớp 1 được tính như sau:

$$\text{Initial Prediction}_1(x) = \log \left(\frac{P(y=1)}{1 - P(y=1)} \right) \quad (1.14)$$

Trong đó: $P(y=1)$ là xác suất tiên nghiệm của lớp 1.

Bước 2: Tính gradient và hessian:

- Gradient và hessian được tính dựa trên hàm mất mát được chọn.
- Đối với phân lớp nhị phân với hàm mất mát cụ thể, gradient và hessian cho điểm dữ liệu (x, y) được tính như sau:

$$\text{Gradient}(x) = - \frac{\partial \text{Loss}}{\partial \text{Initial Prediction}(x)} \quad (1.15)$$

$$\text{Hessian}(x) = \frac{\partial^2 \text{Loss}}{\partial (\text{Initial Prediction}(x))^2} \quad (1.16)$$

Trong đó: Loss là hàm mất mát được chọn và $\frac{\partial}{\partial \text{Initial Prediction}(x)}$ biểu thị đạo hàm riêng theo dự đoán ban đầu.

Bước 3: Xây dựng cây:

- LightGBM xây dựng một tập hợp các cây quyết định bằng cách sử dụng kỹ thuật gradient boosting.
- Mỗi cây được xây dựng bằng cách chia dữ liệu dựa trên giá trị đặc trưng để tối thiểu hóa hàm mất mát được chọn.
- Các cây được xây dựng theo cách tích lũy, trong đó cây mới cố gắng sửa các sai số của tập hợp cây trước đó.

Bước 4: Cập nhật dự đoán:

- Dự đoán được cập nhật bằng cách thêm dự đoán của cây mới vào tập hợp cây trước đó.
- Công thức cập nhật cho dự đoán sau khi thêm cây mới là:

$$\text{Updated Prediction}(x) = \text{Previous Prediction}(x) + \eta \cdot \text{Tree Prediction}(x) \quad (1.17)$$

Trong đó:

- + η là tỷ lệ học tập
- + $\text{Previous Prediction}(x)$ là dự đoán trước đó cho điểm dữ liệu x
- + $\text{Tree Prediction}(x)$ là dự đoán của cây mới cho điểm dữ liệu x .

d. Thuật toán học sâu: Feedforward Neural Network (FNN) và Convolutional Neural Network (CNN)

Feedforward Neural Network (FNN): Feedforward Neural Network - FNN (mạng nơ-ron truyền thẳng) là một mô hình học sâu, trong đó mục tiêu được biểu diễn thông qua một hàm f^* . Ví dụ, trong trường hợp bài toán phân lớp, $y = f^*(x)$ ánh xạ một đầu vào x vào một danh mục y . Mạng truyền thẳng xác định một ánh xạ $y = f(x; \theta)$ và học giá trị của các tham số θ để đạt được hàm mục tiêu tốt nhất [15].

FNN là một loại cụ thể của mạng nơ-ron nhân tạo (ANN). Mạng nơ-ron nhân tạo là một kỹ thuật học máy khám phá các mối quan hệ trong dữ liệu mà không yêu cầu kiến thức cụ thể về lĩnh vực dữ liệu. Cấu trúc của ANN mô phỏng não người. Đơn vị cơ bản của ANN được gọi là nơ-ron nhân tạo. Khi nhận được tín hiệu đầu vào, nó sẽ gửi tín hiệu đầu ra đến các nơ-ron tiếp theo, phụ thuộc vào độ lớn của đầu vào. Với ANN, các nơ-ron nhân tạo được gọi là nơ-ron để đơn giản hóa. Các nơ-ron được tổ chức thành các nhóm gọi là tầng (layer). Trong FNN, các tầng kết nối theo thứ tự, đầu ra từ các nơ-ron của một tầng kết nối với đầu vào của các nơ-ron trong tầng kế tiếp. Các kết nối giữa các nơ-ron trong mỗi tầng được gán trọng số, biểu thị sức mạnh của kết nối giữa hai nơ-ron. Sự kết hợp của các tầng và các kết nối có trọng số giữa chúng tạo thành mạng nơ-ron [29].

Nơ-ron N nhận n đầu vào và tính tổng có trọng số của các đầu vào:


$$s = w^T \cdot a + b \quad (1.18)$$

Trong phương trình (1.18), vector cột a chứa vector các đầu vào nhận được bởi N , trong khi vector w chứa tất cả các trọng số liên quan đến mỗi đầu vào. Đầu vào thứ i , a_i , được nhân với trọng số kết nối thứ i , w_i . b là một số vô hướng được gọi là bias, được sử dụng để dịch kết quả từ một hàm sang trái hoặc sang phải. Hàm kích hoạt phi tuyến tính $\sigma(s) = z$ tạo ra giá trị đầu ra z , sau đó được đưa vào các nơ-ron tiếp theo.

Các nơ-ron trong mạng nơ-ron được sắp xếp thành các tầng. Với FNN, mỗi nơ-ron trong một tầng chỉ kết nối với tất cả các nơ-ron trong tầng tiếp theo, trừ các nơ-ron trong tầng đầu ra. Hình 1.1 trình bày một ví dụ về FNN. Phương trình (1.18) có thể được tổng quát hóa thành:

$$s = Wa + b \quad (1.19)$$

Để xem xét tất cả các nơ-ron trong một tầng và các kết nối của chúng với tầng tiếp theo. Ở đây, W là ma trận có kích thước $m \times n$ chứa các kết nối trọng số giữa hai tầng, trong đó m là số đầu ra từ tầng trước đó và n biểu thị số nơ-ron trong tầng hiện tại. a là đầu vào từ tất cả các nơ-ron trong tầng trước đó, và vector b chứa các bias liên quan đến



Hình 1.1. Ví dụ mô hình FNN [29].

các tín hiệu được chuyển từ một tầng sang tầng khác. Sử dụng hàm kích hoạt σ , tất cả các đầu ra từ một tầng được tính như sau:

$$\sigma(s) = z \quad (1.20)$$

trong đó z_i bất kỳ là đầu ra của một nơ-ron duy nhất trong tầng đó.

Một mạng nơ-ron nhân tạo cơ bản bao gồm một tầng đầu vào, một hoặc nhiều tầng ẩn và một tầng đầu ra. Các tầng cùng nhau phân loại đầu vào x bằng cách kết hợp một nhân y với đầu vào. Một số L tầng biến đổi đầu vào x theo công thức:

$$z(L) = \sigma(L)(W(L) \dots (\sigma(2)(W(2)\sigma(1)(W(1)x + b(1)) + b(2)) \dots + b(L))) \quad (1.21)$$

trong đó $\sigma(i)$, $W(i)$ và $b(i)$ lần lượt biểu thị hàm kích hoạt, các trọng số liên quan và vector bias của tầng thứ i . Kết quả của tầng cuối cùng, $z(L)$ được so sánh với phân loại thực tế của điểm dữ liệu y để xác định độ chính xác của mạng. $z(L)$ có thể được biểu diễn dưới dạng số vô hướng $\hat{y}$. Đối với bài toán phân lớp, mỗi giá trị $z(L)$ đại diện cho xác suất của một lớp cụ thể, và lớp có xác suất cao nhất sẽ được chọn. Do đó, $\hat{y}$ là nhãn tương ứng và trong bài báo này, $\hat{y}$ luôn là kết quả của FNN.

Lựa chọn của hàm kích hoạt σ xác định hành vi của một tầng trong mạng nơ-ron. Lưu ý rằng dù đầu vào của σ là một vector, thì phép toán được áp dụng cho từng phần tử của vector đó. Nếu σ là một hàm tuyến tính như hàm đồng nhất $\sigma(x) = x$, thì $z = s$ và $z = Wa + b$. Với σ tuyến tính, tầng này áp dụng phép biến đổi gần như là phân tích thành phần chính (PCA), một kỹ thuật giúp ánh xạ dữ liệu có số chiều cao xuống số chiều thấp sao cho phương sai lớn nhất từ tập dữ liệu ban đầu được bảo tồn. Tuy nhiên, có sự

khác biệt giữa PCA tiêu chuẩn và biến thể này. Thứ nhất, W không phải là các vector riêng hay các thành phần chính của ma trận trọng số W , trong đó a thuộc tập dữ liệu $D \in \mathbb{R}^{n \times p}$. Thứ hai, bias b , không tồn tại trong PCA cổ điển, dịch chuyển các điểm dữ liệu trên các trục tương ứng. Nếu σ là không tuyến tính, thì tầng mạng có thể gần đúng hơn các mối quan hệ phi tuyến, phức tạp và phổ biến hơn trong các tình huống thực tế. Hai hàm phi tuyến thông thường được sử dụng trong FNN là đơn vị tuyến tính (ReLU) được định nghĩa là

$$\sigma(x) = \max(0, x) \quad (1.22)$$

và hàm sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1.23)$$

Mạng FNN càng có nhiều tầng ẩn với σ phi tuyến tính, thì mạng càng sâu. Mạng sâu có khả năng biểu diễn cao hơn so với mạng với ít tầng hơn. Việc thêm nhiều tầng mô phỏng định lý xấp xỉ toàn diện, mô tả rằng hàm

$$G(x) = \sum_{i=1}^n \alpha_i \sigma(w_i^T x + b_i) \quad (1.24)$$

trong đó α_i là trọng số và σ là bất kỳ hàm sigmoid liên tục nào, xấp xỉ hàm f . Tuy nhiên, sự khác biệt giữa định lý này và FNN hiện đại là trong FNN, σ trong mỗi tầng có thể khác nhau và đầu ra của bất kỳ tầng nào được sử dụng làm đầu vào cho tầng tiếp theo thay vì là tổng có trọng số của đầu ra của tất cả các tầng.

Convolutional Neural Network (CNN): Mạng tích chập (Convolutional networks), còn được gọi là mạng nơ-ron tích chập (convolutional neural networks hay CNNs), là một loại mạng nơ-ron đặc biệt được sử dụng để xử lý dữ liệu có cấu trúc lưới đã biết trước. Mạng tích chập đã đạt được thành công vượt trội trong các ứng dụng thực tế. Tên gọi "mạng nơ-ron tích chập" cho thấy mạng này sử dụng một phép toán toán học gọi là tích chập (convolution). Tích chập là một loại phép toán tuyến tính đặc biệt. Mạng tích chập đơn giản là mạng nơ-ron sử dụng phép toán tích chập thay vì phép nhân ma trận tổng quát ít nhất trong một trong số các tầng của nó [15].

Trong CNN, có ba loại lớp quan trọng và phổ biến: lớp tích chập (convolution layer), lớp gộp (pooling layer) và lớp được kết nối đầy đủ (fully connected layers). Các lớp này tương ứng với việc trích xuất đặc trưng, giảm kích thước và phân loại. Các lớp này được xếp chồng lên nhau để tạo thành một mạng CNN đầy đủ [44].

Lớp tích chập: Phép tích chập $(x * w)(a)$ của hai hàm x và w được định nghĩa trong

tất cả các chiều như sau:

$$(x * w)(a) = \int x(t)w(a - t)da \quad (1.25)$$

trong đó a thuộc $\mathbb{R}^n$ với $n \geq 1$, và phép tích phân được thay thế bằng biến thể nhiều chiều của nó. Theo thuật ngữ của mạng nơ-ron tích chập, x được gọi là đầu vào (input), w được gọi là bộ lọc hoặc nhân (filter hoặc kernel), và kết quả đầu ra thường được gọi là hoạt động (activation) hoặc bản đồ đặc trưng (feature map) [44].

Lớp Pooling Mục tiêu của một lớp pooling là tạo ra một thống kê tóm tắt của đầu vào và giảm kích thước không gian của bản đồ đặc trưng. Để làm được điều này, lớp max pooling sẽ báo cáo các giá trị lớn nhất trong mỗi khu vực chữ nhật xung quanh mỗi điểm (i, j) (hoặc (i, j, k) cho dữ liệu 3D) của mỗi đặc trưng đầu vào trong khi lớp average pooling sẽ báo cáo các giá trị trung bình. Hình thức max pooling phổ biến nhất sử dụng bước nhảy (stride) 2 cùng với kích thước kernel (cửa sổ) 2, tương ứng với việc chia bản đồ đặc trưng ra thành lưới hình vuông hoặc hình lập phương có cạnh là 2 và lấy giá trị lớn nhất hoặc trung bình của các khối như vậy cho mỗi đặc trưng đầu vào.

Mặc dù các phép tổng hợp thông thường là thành phần xây dựng phổ biến trong CNNs khi mục tiêu là giảm chiều không gian của bản đồ đặc trưng, nhưng cần lưu ý rằng ta cũng có thể đạt được mục tiêu tương tự bằng cách sử dụng, ví dụ, tích chập 3×3 với bước nhảy 2 nếu làm việc với dữ liệu 2D. Trong trường hợp này, ta cũng có thể đồng thời tăng gấp đôi số bộ lọc để giảm mất mát thông tin trong khi tổng hợp các đặc trưng cấp cao hơn [44].

Lớp fully connected với n chiều đầu vào và m chiều đầu ra được định nghĩa: Đầu ra của lớp được xác định bởi các tham số sau: ma trận trọng số $W \in \mathbb{R}^{m \times n}$ có m hàng và n cột, và vector bias $b \in \mathbb{R}^m$. Cho vector đầu vào $x \in \mathbb{R}^n$, đầu ra của lớp fully connected FC với hàm kích hoạt f được xác định như sau:

$$FC(x) := f(Wx + b) \in \mathbb{R}^m. \quad (1.26)$$


Trong công thức trên, Wx là tích ma trận và hàm f được áp dụng từng phần tử. Lớp fully connected thường được sử dụng làm lớp cuối cùng trong các bài toán phân loại, trong đó một số lớp fully connected (thường là một hoặc hai lớp) được gắn kết lên đầu của một CNN. Để làm điều này, đầu ra của CNN được làm phẳng và coi như một vector duy nhất. Một ví dụ khác là các kiến trúc autoencoder khác nhau, trong đó các lớp FC thường được gắn kết với mã code ẩn trong cả đường đi của bộ mã hóa và bộ giải mã của mạng. Khi làm việc với mạng nơ-ron tích chập, hữu ích để nhận ra rằng đối với một bản đồ đặc trưng với n kênh, ta có thể áp dụng một bộ lọc tích chập với kích thước kernel là 1 và m kênh đầu ra, điều này sẽ tương đương với áp dụng một lớp fully connected cùng

m với mỗi điểm trên bản đồ đặc trưng [44].

e. Phương pháp Xếp chồng (Stacking):

Xếp chồng (Stacking hay Stacked Generalization) là một thuật toán học máy thuộc Ensemble Learning, được sử dụng để kết hợp dự đoán từ nhiều mô hình học máy khác nhau trên cùng một tập dữ liệu. Tương tự như thuật toán đóng bao và Tăng cường, xếp chồng nhằm tăng cường khả năng dự đoán của mô hình bằng cách kết hợp sự đa dạng và sự chuyên sâu của các mô hình con.

Kiến trúc của phương pháp xếp chồng bao gồm việc xây dựng một số mô hình con, thường là các loại mô hình khác nhau, và một mô hình chủ đạo (supervisor model). Mô hình chủ đạo này học cách kết hợp kết quả dự đoán từ các mô hình con một cách tốt nhất [4]. Ở đây, các mô hình riêng lẻ được gọi là mô hình cấp độ một, trong khi mô hình kết hợp được gọi là mô hình cấp độ hai hoặc mô hình meta-learner. Ý tưởng cơ bản là huấn luyện các mô hình cấp độ một bằng cách sử dụng tập dữ liệu huấn luyện gốc, sau đó tạo ra một tập dữ liệu mới để huấn luyện mô hình cấp độ hai, trong đó đầu ra của các mô hình cấp độ một được coi là các đặc trưng đầu vào trong khi các nhãn gốc vẫn được coi là nhãn của dữ liệu huấn luyện mới. Các mô hình cấp độ một thường được tạo ra bằng cách áp dụng các thuật toán học khác nhau, và vì vậy, các bộ tổ hợp stacked thường không đồng nhất, mặc dù cũng có thể xây dựng các bộ tổ hợp stacked đồng nhất [50]. Hình 1.2 dưới đây mô tả kiến trúc chung của một mô hình được xây dựng dựa trên kỹ thuật xếp chồng:



Hình 1.2. Kiến trúc tổng quan của mô hình xếp chồng [39].

Trong hình 1.2:

- Original Data: Dữ liệu ban đầu được chia thành n-folds
- Mô hình học máy cơ sở: Các mô hình cấp độ 1 (base models).
- Level 1 Predictions: Dự đoán được tạo ra bởi các mô hình cơ sở trên dữ liệu gốc.
- Level 2 Model - Meta-Learner (mô hình tổng hợp), mô hình kết hợp các dự đoán cấp độ 1 để tạo ra dự đoán cuối cùng tốt nhất.

f. Phương pháp Bỏ phiếu (Voting): Bỏ phiếu (Voting) là một phương pháp phổ biến trong học kết hợp, trong đó nhiều bộ phân loại đưa ra dự đoán về một mẫu dữ liệu

và kết quả cuối cùng được xác định bằng cách kết hợp các dự đoán đó [50].

Có các dạng chính của phương pháp Bỏ phiếu như sau [50]:

- Bỏ phiếu cứng (Hard Voting): là phương pháp đơn giản trong đó mỗi bộ phân loại trong ensemble đưa ra một phiếu bầu cho một nhãn lớp, và kết quả cuối cùng được quyết định bằng cách chọn nhãn lớp nhận được phiếu bầu nhiều nhất. Nếu không có nhãn lớp nào nhận được số phiếu bầu nhiều hơn một nửa, ta có thể chọn sự từ chối và ensemble không đưa ra dự đoán. Bỏ phiếu cứng phù hợp khi các bộ phân loại trong ensemble có độ chính xác tương tự và không có sự chênh lệch đáng kể về hiệu suất.

- Bỏ phiếu mềm (Soft Voting): là phương pháp sử dụng xác suất dự đoán của các bộ phân loại để tính toán kết quả cuối cùng. Mỗi bộ phân loại trong ensemble đưa ra dự đoán xác suất cho các lớp hoặc nhãn, và kết quả cuối cùng được tính bằng cách lấy trung bình hoặc trọng số của các xác suất này. Bỏ phiếu mềm giúp tận dụng thông tin chi tiết từ các dự đoán xác suất và có thể cải thiện khả năng tổng quát hóa của ensemble. Điều này đặc biệt hữu ích khi các bộ phân loại có khả năng đưa ra xác suất dự đoán chính xác.

- Bỏ phiếu có trọng số (Weighted Voting): là phương pháp gán trọng số cho các bộ phân loại trong ensemble dựa trên độ tin cậy của chúng. Mỗi bộ phân loại được gán một trọng số tương ứng với độ tin cậy của nó. Khi kết hợp các dự đoán, trọng số này được sử dụng để tính toán kết quả cuối cùng. Bỏ phiếu có trọng số cho phép các bộ phân loại có độ tin cậy cao hơn có ảnh hưởng lớn hơn đến kết quả cuối cùng. Điều này giúp tận dụng thông tin từ các bộ phân loại chất lượng cao và cải thiện hiệu suất dự đoán của ensemble.

Ba phương pháp đều có ưu điểm riêng và việc lựa chọn phương pháp Bỏ phiếu phụ thuộc vào đặc điểm của bài toán và các bộ phân loại trong ensemble. Việc kết hợp các dự đoán từ nhiều bộ phân loại thông qua Bỏ phiếu là một cách hiệu quả để tận dụng đa dạng và kiến thức của các mô hình khác nhau, đồng thời cải thiện khả năng dự đoán tổng thể của mô hình ensemble.

1.4.3. Phương pháp đánh giá mô hình

Các chỉ số hiệu suất được sử dụng để đánh giá mô hình dự đoán hành vi khách hàng từ một số nghiên cứu cập nhật được trình bày trong Bảng 1.3. Nhận thấy, các chỉ số Accuracy, F-Measure, AUC là những chỉ số hiệu suất được sử dụng phổ biến trong các nghiên cứu đi trước. Trong đó, F-Measure là một chỉ số được tính dựa trên hai chỉ số Recall và Precision. Vì vậy, luận văn tập trung vào sử dụng Accuracy, Area Under the Curve (AUC) và F-Measure để đánh giá hiệu suất mô hình dự đoán. Các chỉ số này được tính toán dựa trên ma trận nhầm lẫn (bao gồm 4 thành phần TP, TN, FP, FN) với bài toán dự đoán hành vi khách hàng 2 lớp và đa lớp (lớn hơn 2 lớp) được trình bày dưới đây.

1.4.3.1. Phương pháp đánh giá mô hình đối với bộ dữ liệu với biến mục tiêu bao gồm 2 lớp

Với bộ dữ liệu có biến mục tiêu bao gồm 2 lớp, ma trận nhầm lẫn cần được xác định dựa trên các thành phần như sau:

- True Positive (TP): Các mẫu thuộc lớp dương (positive) được dự đoán đúng là thuộc lớp dương.
- True Negative (TN): Các mẫu thuộc lớp âm (negative) được dự đoán đúng là thuộc lớp âm.
- False Positive (FP): Các mẫu thuộc lớp âm được dự đoán sai là thuộc lớp dương.
- False Negative (FN): Các mẫu thuộc lớp dương được dự đoán sai là thuộc lớp âm.

Bảng 1.3. Phương pháp đánh giá mô hình dự đoán hành vi khách hàng.

Nguồn	Các phương pháp đánh giá mô hình
[12, 24, 32, 33, 41]	ACC, Recall, Precision, F-Measure, AUC
[1, 20, 34]	ACC, Recall, Precision, F-Measure
[9, 47]	ACC, F-Measure
[5]	ACC, AUC, TDL, F-Measure, EMPC
[19]	ACC, AUC, RMSE
[2]	ACC, Recall, Precision, F-Measure, FOR
[45, 46]	ACC, AUC, F-Measure
[37]	ACC, Fitness Function, OFS, Computational Time
[7, 36]	ACC
[43]	ACC, AUC, F-Measure, MCC, Kappa, Brier Score, EMPC
[48]	ACC, Recall, Precision, F-Measure, Computational Time
Chú thích: ACC: Accuracy; AUC: Area Under the Curve; TDL: The Top-Decile Lift; EMPC: The Expected Maximum Profit of the Customer Churn; RMSE: Root Mean Squared Error; FOR: False Omission rate; OFS: Optimum Feature Subsets; MCC: Mathews Correlation Coefficient.	

Với các thành phần trên, các chỉ số hiệu suất được xác định như sau:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (1.27)$$

$$Precision = \frac{TP}{TP + FP} \quad (1.28)$$

Probability of Detection (POD)/ Thu hồi là một số liệu quan trọng trong bài toán nhị phân (2 lớp) để đánh giá khả năng dự đoán các mẫu thuộc lớp dương (positive). Nó được tính như sau:

$$POD/Recall = \frac{TP}{FN + TP} \quad (1.29)$$

Probability of False Detection (POF), còn được gọi là Tỷ lệ dương tính giả, là một số liệu quan trọng trong bài toán nhị phân để đánh giá khả năng dự đoán sai các mẫu thuộc lớp âm (negative). Lý tưởng nhất là POF phải có giá trị bằng 0 và càng thấp càng tốt. Nó được định nghĩa là:

$$POF/FalsePositiveRate = \frac{FP}{TN + FP} \quad (1.30)$$

Diện tích dưới đường cong (AUC): AUC được tính toán bằng cả POF và POD [3, 49]. Giá trị AUC cao hơn cho thấy hiệu suất mô hình tốt hơn. AUC được phát biểu về mặt toán học là:

$$AUC = \frac{1 + POD - POF}{2} \quad (1.31)$$

F-Measure: thể hiện giá trị trung bình điều hòa của Recall, Precision và được sử dụng để tìm ra sự dung hòa giữa hai chỉ số. Giá trị F-Measure bằng 1 cho biết mô hình hoàn hảo. Công thức tính F-Measure là:

$$F - Measure = \frac{2 * precision * recall}{precision + recall} \quad (1.32)$$

1.4.3.2. Phương pháp đánh giá mô hình đối với bộ dữ liệu với biến mục tiêu bao gồm đa lớp

Với bộ dữ liệu có biến mục tiêu có đa lớp, ma trận nhầm lẫn cần được xác định dựa trên các thành phần như sau:

- True Positive (TP): Số lượng mẫu thuộc một lớp cụ thể được dự đoán chính xác là thuộc lớp đó. Đây là những trường hợp mà mô hình phân loại đúng các mẫu thuộc lớp cần quan tâm.
- True Negative (TN): Số lượng mẫu thuộc các lớp khác lớp quan tâm được dự đoán chính xác là không thuộc lớp quan tâm. Đây là những trường hợp mà mô hình phân loại đúng các mẫu thuộc các lớp không cần quan tâm.
- False Positive (FP): Số lượng mẫu thuộc các lớp khác lớp quan tâm được dự đoán không chính xác là thuộc lớp quan tâm. Đây là những trường hợp mà mô hình dự

đoán sai bằng cách cho rằng mẫu thuộc các lớp không cần quan tâm thực tế lại thuộc lớp quan tâm.

- False Negative (FN): Số lượng mẫu thuộc lớp quan tâm được dự đoán không chính xác là không thuộc lớp quan tâm. Đây là những trường hợp mà mô hình dự đoán sai bằng cách cho rằng mẫu thuộc lớp quan tâm thực tế lại thuộc các lớp không cần quan tâm.

Trong bài toán dự đoán hành vi khách hàng với biến mục tiêu bao gồm nhiều hơn 2 lớp, hay còn gọi là đa lớp, các chỉ số hiệu suất trên được tính theo giá trị Micro-averaged. Dưới đây là các công thức tính toán các chỉ số hiệu suất trên dựa vào các thành phần của ma trận nhầm lẫn đã đề cập:

Micro-averaged Accuracy:

$$\text{Micro-averaged Accuracy} = \frac{\sum_{i=1}^N (TP_i + TN_i)}{\sum_{i=1}^N (TP_i + TN_i + FP_i + FN_i)}$$

Micro-averaged Precision:

$$\text{Micro-averaged Precision} = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FP_i)}$$

Micro-averaged Recall (POD):

$$\text{Micro-averaged Recall} = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FN_i)}$$

Probability of False Detection (POF):

$$\text{POF/False Positive Rate} = \frac{\sum_{i=1}^N FP_i}{\sum_{i=1}^N (TN_i + FP_i)}$$

Diện tích dưới đường cong (AUC):

$$\text{AUC} = \frac{1 + \text{POD} - \text{POF}}{2}$$

Micro-averaged F1-score:

$$\text{Micro-averaged F1-score} = \frac{2 \times (\text{Micro-averaged Precision} \times \text{Micro-averaged Recall})}{\text{Micro-averaged Precision} + \text{Micro-averaged Recall}}$$

Kết luận chương

Chương một của luận văn đã giới thiệu bài toán và trình bày tổng quan lý thuyết liên quan đến đề tài dự đoán hành vi khách hàng. Dựa trên những kiến thức đã được đề

cập, chương tiếp theo của luận văn trình bày một quy trình được đề xuất để giải quyết bài toán dự đoán hành vi của khách hàng.

CHƯƠNG 2

QUY TRÌNH ĐỀ XUẤT DỰ ĐOÁN HÀNH VI KHÁCH HÀNG

Dựa trên kết quả khảo sát một số nghiên cứu cập nhật liên quan đến bài toán dự đoán hành vi khách hàng về các khía cạnh: (1) Ưu, nhược điểm của các phương pháp tiền xử lý dữ liệu; (2) Các phương pháp học máy cho hiệu suất tốt và khoảng trống nghiên cứu thu được sau khi khảo sát về các phương pháp đó; và (3) Phương pháp đánh giá mô hình dự đoán hành vi khách hàng, luận văn trình bày mô hình dự đoán hành vi khách hàng được minh họa trong Hình 2.1, bao gồm năm bước: (1) Tìm kiếm và lựa chọn dữ liệu; (2) Tiền xử lý dữ liệu; (3) Trích chọn đặc trưng; (4) Xây dựng mô hình phân lớp hành vi khách hàng; và (5) Kiểm tra chéo, đưa ra kết quả và phân tích.


Các bước trong phương pháp đề xuất (Hình 2.1) được đề xuất bởi nhóm nghiên cứu và được công bố trong báo cáo tham dự hội nghị SOICT 2023¹. Trong bài báo đó¹, 4 bộ dữ liệu đã được thực nghiệm, bao gồm 3 bộ dữ liệu về hành vi rời bỏ (bộ dữ liệu Cell2cell, Campaign và Bank), 1 bộ dữ liệu về tần suất mua hàng của khách hàng (Bộ dữ liệu Online shoppers). Học viên đưa vào luận văn kết quả thực nghiệm của các bộ dữ liệu mà học viên chịu trách nhiệm thực nghiệm trong bài báo¹, đó là 3 bộ dữ liệu về hành vi rời bỏ. Thêm vào đó, để chứng minh bổ sung về tính linh hoạt của phương pháp đề xuất, học viên thực nghiệm và trình bày thêm trong luận văn 1 bộ dữ liệu về tần suất mua hàng của khách hàng (bộ dữ liệu Customer Shopping Trends). Như vậy, 4 bộ dữ liệu được luận văn sử dụng để áp dụng quy trình đề xuất dự đoán hành vi khách hàng bao gồm:

- 3 bộ dữ liệu về hành vi rời bỏ: bộ dữ liệu Cell2cell, bộ dữ liệu Campaign và bộ dữ liệu Bank
- 1 bộ dữ liệu về tần suất mua hàng của khách hàng: bộ dữ liệu Customer Shopping Trends

2.1. Tìm kiếm và lựa chọn dữ liệu

Trước khi xây dựng mô hình phân lớp, việc tìm kiếm và lựa chọn dữ liệu phù hợp là một bước quan trọng để đảm bảo tính đáng tin cậy và hiệu quả của mô hình. Luận văn

¹Thi Minh Nguyen, Thi An Le, and Thi Hau Nguyen. 2023. A flexible framework for customer behavior prediction based on ensemble learning. In The 12th International Symposium on Information and Communication Technology (SOICT 2023), December 07–08, 2023, Ho Chi Minh, Vietnam. ACM, New York, NY, USA. <https://doi.org/10.1145/3628797.3628973>



Hình 2.1. Quy trình đề xuất dự đoán hành vi của khách hàng.

Bảng 2.1. Tóm tắt các bộ dữ liệu được sử dụng

Description	Cell2cell ¹	Campaign ²	Bank ³	Customer Shopping Trends ⁴
Số bản ghi	71,047	41,188	10,000	3,900
Số lượng trường dữ liệu	71	17	12	18
Số lượng lớp	2	2	2	7

đã tiến hành tìm kiếm và lựa chọn bộ dữ liệu từ các nguồn khác nhau để đáp ứng yêu cầu nghiên cứu và mục tiêu xây dựng mô hình phân lớp dự đoán hành vi của khách hàng.

Luận văn sử dụng bốn bộ dữ liệu được tóm tắt trong Bảng 2.1, bao gồm ba bộ dữ liệu về khách hàng rời bỏ (bộ dữ liệu Cell2cell, bộ dữ liệu Campaign và bộ dữ liệu Bank) và một bộ dữ liệu về tần suất mua hàng của khách hàng (bộ dữ liệu Customer Shopping Trends). Việc sử dụng các bộ dữ liệu liên quan đến cả dự đoán tỷ lệ rời bỏ khách hàng và dự đoán tần suất mua hàng của khách hàng làm nổi bật tính linh hoạt của khung đề xuất của luận văn.

(1) Bộ dữ liệu Cell2cell về hành vi rời bỏ:

Bộ dữ liệu Cell2cell, được lựa chọn từ kho dữ liệu trực tuyến Kaggle, liên quan đến lĩnh vực viễn thông và tình trạng chuyển mạng của khách hàng. Bộ dữ liệu này cung cấp thông tin về việc rời bỏ dịch vụ viễn thông của khách hàng từ một nhà cung cấp dịch vụ sang nhà cung cấp khác.

Bộ dữ liệu này chứa các thông tin về 71,047 bản ghi khách hàng và bao gồm 71 trường dữ liệu khác nhau như số điện thoại, tuổi, giới tính, địa chỉ, thông tin hợp đồng, các thông tin về cuộc gọi và tin nhắn, dữ liệu về sử dụng dịch vụ truyền dẫn và dữ liệu thanh toán.

Mục tiêu của bộ dữ liệu Cell2cell là phân loại khách hàng liệu có chuyển mạng hay không dựa trên các trường dữ liệu liên quan. Điều này có thể giúp nhà cung cấp dịch vụ viễn thông hiểu được các yếu tố ảnh hưởng đến quyết định chuyển mạng của khách hàng và từ đó đưa ra các biện pháp cải thiện chất lượng dịch vụ và tăng tính cạnh tranh trên thị trường.

(2) Bộ dữ liệu Campaign về hành vi rời bỏ:

Bộ dữ liệu Campaign, được tải xuống từ UCI Machine Learning Repository, liên quan đến các chiến dịch tiếp thị trực tiếp (gọi điện thoại) của một ngân hàng Bồ Đào Nha. Mục tiêu phân loại là dự đoán liệu khách hàng có đăng ký gửi tiền gửi kỳ hạn hay không (biến mục tiêu "y").

Bộ dữ liệu Campaign chứa các thông tin về 41,188 bản ghi dữ liệu và bao gồm 17

¹<https://www.kaggle.com/jpacse/telecom-churn-new-cell2cell-dataset>.

²<https://archive.ics.uci.edu/dataset/222/bank+marketing>.

³<https://www.kaggle.com/datasets/shrutimechlearn/churn-modelling>.

⁴<https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset>.

trường dữ liệu như sau:

- y: Biến mục tiêu, cho thấy Khách hàng có đăng ký gửi tiền gửi không? (y nhận giá trị "yes" hoặc "no")

- age: Độ tuổi của khách hàng.

- job: Loại công việc của khách hàng.

- marital: Tình trạng hôn nhân của khách hàng.

- education: Trình độ học vấn của khách hàng.

- default: Khách hàng có tín dụng trong tình trạng mặc định hay không.

- balance: Số dư trung bình hàng năm của khách hàng (tính bằng Euro).

- housing: Khách hàng có khoản vay mua nhà hay không.

- loan: Khách hàng có khoản vay cá nhân hay không.

- contact: Loại hình liên lạc trong chiến dịch hiện tại.

- day: Ngày cuối cùng trong tháng mà khách hàng được liên hệ.

- month: Tháng cuối cùng trong năm mà khách hàng được liên hệ.

- duration: Thời lượng cuộc liên hệ cuối cùng với khách hàng (tính bằng giây).

- campaign: Số lượng cuộc liên hệ đã thực hiện trong chiến dịch hiện tại và đối với khách hàng này.

- pdays: Số ngày đã trôi qua sau khi khách hàng được liên hệ lần cuối từ chiến dịch trước đó (-1 có nghĩa là không có cuộc liên hệ trước đó).

- previous: Số lượng cuộc liên hệ đã thực hiện trước chiến dịch hiện tại và đối với khách hàng này.

- poutcome: Kết quả của chiến dịch tiếp thị trước đó.

(3) Bộ dữ liệu Bank về hành vi rời bỏ:

Bộ dữ liệu Bank, được lựa chọn từ kho dữ liệu trực tuyến Kaggle, chứa thông tin chi tiết về khách hàng của ngân hàng và biến mục tiêu là biến nhị phân phản ánh thực tế khách hàng đã rời ngân hàng (đóng tài khoản) hay tiếp tục là khách hàng. Bộ dữ liệu này chứa các thông tin về 10,000 bản ghi dữ liệu và bao gồm 12 trường dữ liệu như sau:

- Exited: Biến mục tiêu, thể hiện trạng thái khách hàng đã rời bỏ (churn) hay chưa (1 - Đã rời bỏ, 0 - Chưa rời bỏ).

- RowNumber: Số thứ tự của mỗi hàng trong bộ dữ liệu.

- CustomerId: Mã khách hàng duy nhất của mỗi khách hàng.

- Surname: Họ của khách hàng.

- CreditScore: Điểm tín dụng của khách hàng, là một chỉ số đo lường khả năng trả nợ và lịch sử tín dụng.

- Geography: Quốc gia nơi khách hàng đang sinh sống.
- Gender: Giới tính của khách hàng.
- Age: Tuổi của khách hàng.
- Tenure: Số năm khách hàng đã là thành viên của ngân hàng.
- Balance: Số dư tài khoản của khách hàng.
- NumOfProducts: Số lượng sản phẩm ngân hàng mà khách hàng đang sử dụng.
- HasCrCard: Trạng thái có thẻ tín dụng hay không.
- IsActiveMember: Trạng thái khách hàng có hoạt động hay không (1 - Có, 0 - Không).
- EstimatedSalary: Ước tính thu nhập của khách hàng.

(4) Bộ dữ liệu Customer Shopping Trends về tần suất mua hàng:

Customer Shopping Trends là một tập dữ liệu được lưu trữ trên Kaggle. Bộ dữ liệu này liên quan đến xu hướng mua sắm của khách hàng, bao gồm thông tin lịch sử mua hàng của 3,900 khách hàng với 18 trường dữ liệu như sau:

- Frequency of Purchases: Biến mục tiêu, thể hiện tần suất mua hàng của khách hàng.
- Customer ID: Mã số khách hàng.
- Age: Tuổi của khách hàng.
- Gender: Giới tính của khách hàng.
- Item Purchased: Tên sản phẩm đã mua.
- Category: Danh mục của sản phẩm.
- Purchase Amount (USD): Số tiền mua hàng (đơn vị: USD).
- Location: Địa điểm mua hàng.
- Size: Kích cỡ của sản phẩm.
- Color: Màu sắc của sản phẩm.
- Season: Mùa trong năm mua hàng.
- Review Rating: Đánh giá sản phẩm từ 1 đến 5.
- Subscription Status: Trạng thái đăng ký dịch vụ.
- Shipping Type: Loại hình vận chuyển.
- Discount Applied: Có áp dụng giảm giá hay không.
- Promo Code Used: Sử dụng mã khuyến mãi.
- Previous Purchases: Số lượng mua hàng trước đó.
- Payment Method: Phương thức thanh toán.

—> **Nhận xét: Bốn bộ dữ liệu trên có các đặc điểm chung như sau:**

- Một số trường dữ liệu không liên quan đến quá trình phân lớp (ví dụ: RowNumber, CustomerId, v.v.);
- Không có giá trị nào bị thiếu trong các bộ dữ liệu này;
- Một số trường dữ liệu chứa dữ liệu phân loại;
- Các bộ dữ liệu thể hiện sự mất cân bằng giữa các lớp.

2.2. Tiền xử lý dữ liệu

Dựa trên các đặc điểm chung của các bộ dữ liệu được sử dụng và kết quả khảo sát thu được từ các phương pháp tiền xử lý dữ liệu được thảo luận trong chương 1, luận văn triển khai quy trình tiền xử lý dữ liệu bao gồm sáu bước. So với kết quả khảo sát được tổng hợp từ các nghiên cứu đi trước trong Chương 1 bao gồm bảy bước tiền xử lý dữ liệu, luận văn lược bỏ đi bước (2) liên quan đến việc xử lý các trường dữ liệu và bản ghi bị thiếu giá trị. Bước này không cần thiết đối với các bộ dữ liệu được sử dụng trong luận văn vì chúng đều không chứa giá trị bị thiếu. Trong phần này, luận văn trình bày năm trong số sáu bước tiền xử lý dữ liệu, với bước cuối cùng, trích chọn đặc trưng, sẽ được thảo luận rõ hơn trong phần tiếp theo.

2.2.1. Làm sạch dữ liệu

Trong bước đầu tiên này, luận văn đã loại bỏ các trường dữ liệu không cần thiết như RowNumber, CustomerId,... và những trường dữ liệu không đóng góp vào quá trình phân lớp.

2.2.2. Xử lý dữ liệu phân loại

Các nghiên cứu trước đây đã sử dụng các phương pháp khác nhau để mã hóa dữ liệu phân loại, bao gồm one-hot encoding và label encoding (chẳng hạn: [5, 7, 12, 33]). Để giảm bớt sự phổ biến của số lượng trường dữ liệu, luận văn đã chọn phương pháp label encoding.

Phương pháp Label Encoding là một kỹ thuật biến đổi dữ liệu từ dạng chuỗi thành dạng số nguyên. Nó được sử dụng khi dữ liệu đầu vào chứa các nhãn (labels) không phải dạng số và các thuật toán học máy yêu cầu đầu vào là dạng số. Phương pháp này thực hiện gán một số nguyên duy nhất cho mỗi nhãn trong tập dữ liệu. Các nhãn khác nhau sẽ được gán các số nguyên khác nhau đồng thời giữ nguyên thứ tự của chúng [16].

2.2.3. Biến đổi dữ liệu

Trong các phương pháp biến đổi dữ liệu, WOE (Weight of Evidence) đã được chứng minh là hiệu quả hơn so với các phương pháp biến đổi dữ liệu khác trong các nghiên cứu trước đây (Sana và cộng sự, 2022). Cụ thể, phương pháp này đã cho thấy hiệu quả trong

việc nắm bắt mối quan hệ giữa các trường dữ liệu và biến mục tiêu [33]. Do đó, luận văn đã kết hợp phương pháp WOE vào quy trình biến đổi dữ liệu của luận văn.

WOE là một phương pháp biến đổi dữ liệu sử dụng binning và phép toán logarithm. Mục tiêu chính của WOE là giải quyết sự lệch trong phân phối dữ liệu [33]. Trong nhiều trường hợp, dữ liệu không được phân phối đều và có sự lệch (skewness). Sự lệch này có thể gây ảnh hưởng đến hiệu suất và độ chính xác của các mô hình dự đoán. WOE giúp giải quyết vấn đề này bằng cách biến đổi dữ liệu ban đầu thành các giá trị mới dựa trên binning và phép toán logarithm.

Đầu tiên, WOE thực hiện binning, tức là chia dữ liệu thành các khoảng (bins) dựa trên giá trị của biến độc lập. Sau đó, nó tính toán tỷ lệ giữa các hồ sơ thuộc vào lớp "tốt" (có sự kiện mục tiêu xảy ra) và lớp "xấu" (không có sự kiện mục tiêu xảy ra) cho mỗi khoảng. Tiếp theo, WOE sử dụng giá trị logarithm của tỷ lệ này để tạo ra các giá trị WOE tương ứng. Dưới đây là công thức của phương pháp này [33]:

$$WOE_i = \ln\left(\frac{X_i}{Y_i}\right) \quad (2.1)$$

Trong công thức (2.1):

- WOE_i là giá trị WOE của bin i .
- $\ln$ là hàm logarithm tự nhiên (natural logarithm).
- X_i là phân phối của các sự kiện "tốt" trong bin i .
- Y_i là phân phối của các sự kiện "xấu" trong bin i .

2.2.4. Chuẩn hóa dữ liệu

Dữ liệu không được chuẩn hóa có thể ảnh hưởng xấu đến hiệu suất của mô hình [42]. Để giải quyết vấn đề này, luận văn đã thực hiện chuẩn hóa sử dụng kỹ thuật StandardScaler. Kỹ thuật này được sử dụng khá rộng rãi, chuẩn hóa dữ liệu bằng cách trừ giá trị trung bình và chia cho phương sai, đảm bảo rằng tất cả các trường dữ liệu đều có tỷ lệ tương tự.

Cách hoạt động của StandardScaler là chuyển đổi các biến độc lập sao cho chúng có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này giúp đảm bảo rằng các biến độc lập có cùng đơn vị đo và phân phối tương tự nhau. Quá trình chuẩn hóa này dựa trên công thức sau:

$$X_{\text{standardized}} = \frac{X - \mu}{\sigma} \quad (2.2)$$

Trong công thức (2.2):

- $X_{\text{standardized}}$ là giá trị chuẩn hóa của biến X .
- X là giá trị ban đầu của biến X .

- μ là giá trị trung bình của biến X .
- σ là độ lệch chuẩn (standard deviation) của biến X .

2.2.5. Xử lý dữ liệu mất cân bằng

Theo các tài liệu nghiên cứu trước đây (Dalli, 2022 [7]; Tekouabou và cộng sự, 2022 [43] và Usman-Hamza và cộng sự, 2022 [45]), việc giải quyết tình trạng mất cân bằng dữ liệu là rất quan trọng. Để giải quyết vấn đề này, luận văn sử dụng Kỹ thuật lấy mẫu quá mức cho thiểu số tổng hợp (Synthetic Minority Over-sampling Technique - SMOTE).

SMOTE được sử dụng để tăng cường số lượng mẫu dữ liệu của lớp thiểu số bằng cách tạo ra các mẫu dữ liệu nhân tạo. Cách hoạt động của SMOTE là tạo ra các mẫu dữ liệu nhân tạo bằng cách kết hợp các mẫu dữ liệu của lớp thiểu số đã có, giúp cân bằng tỷ lệ giữa các lớp. Điều này giúp cải thiện khả năng dự đoán của mô hình, đặc biệt là khi mô hình gặp khó khăn trong việc phân loại lớp thiểu số do sự mất cân bằng dữ liệu. SMOTE được thực hiện theo các bước sau:

Bước 1: Chọn ngẫu nhiên một mẫu dữ liệu từ lớp thiểu số.

Bước 2: Tìm k-nearest neighbors (k láng giềng gần nhất) của mẫu dữ liệu đó trong lớp thiểu số.

Bước 3: Chọn ngẫu nhiên một láng giềng trong k láng giềng đó.

Bước 4: Tạo một mẫu dữ liệu nhân tạo mới bằng cách lấy một tỷ lệ của sự khác biệt giữa mẫu dữ liệu gốc và láng giềng đã chọn và thêm vào mẫu dữ liệu gốc.

2.3. Trích chọn đặc trưng

Luận văn đã xây dựng mô hình hồi quy đa biến để xác định các yếu tố ảnh hưởng đến hành vi của khách hàng. Với tập hợp các đặc trưng thu được sau khi thực hiện năm bước tiền xử lý dữ liệu đã trình bày ở phần trước, luận văn sử dụng phần mềm thống kê SPSS để xây dựng mô hình hồi quy tuyến tính với biến phụ thuộc là hành vi của khách hàng. Mô hình hồi quy tuyến tính có công thức chung như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon \quad (2.3)$$

Trong công thức (2.3):

- Y là biến phụ thuộc.
- $X_1, X_2, \dots, X_p$ là các đặc trưng.
- $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ là các hệ số hồi quy.
- ϵ là sai số ngẫu nhiên.

Cụ thể, phương pháp được sử dụng trong SPSS để xây dựng mô hình hồi quy tuyến tính là phương pháp bình phương nhỏ nhất (Least Squares Method). Phương pháp này

tìm cách tối thiểu hóa sai số giữa giá trị dự đoán của mô hình và giá trị thực tế của biến phụ thuộc (ϵ) bằng cách tìm các giá trị tối ưu cho các hệ số $\beta_0, \beta_1, \beta_2, \dots, \beta_p$. Bên cạnh tìm ra các hệ số β , luận văn tiến hành kiểm định ý nghĩa của hệ số này với phương pháp t-Test. Phương pháp này sử dụng phân phối t-Student để kiểm tra ý nghĩa của hệ số β . Trong đó, giá trị t-score và p-value tương ứng cần được tính toán:

- Giá trị t-score được tính bằng cách chia hệ số β cho sai số tiêu chuẩn của β .

- P-value là xác suất để có giá trị t-score lớn hơn hoặc bằng giá trị t-score quan sát được. Các đặc trưng có p-value nhỏ hơn mức ý nghĩa đã chọn (0.05) được xác định là có ý nghĩa trong mô hình và được giữ lại. Với các đặc trưng có p-value lớn hơn 0.05, đặc trưng nào có p-value lớn nhất sẽ được lựa chọn để loại ra khỏi mô hình. Các đặc trưng còn lại được sử dụng để xây dựng mô hình hồi quy lần tiếp theo. Quá trình này được thực hiện lặp lại cho đến khi tất cả các đặc trưng đều có p-value nhỏ hơn 0.05, điều này đảm bảo tất cả các đặc trưng đó đều có ý nghĩa đến biến phụ thuộc (hành vi của khách hàng).

Sau khi xây dựng mô hình hồi quy tuyến tính các đặc trưng ảnh hưởng tới hành vi của khách hàng, luận văn sử dụng phần mềm thống kê SPSS để vẽ biểu đồ Scatter Plot kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình. Cách bố trí của điểm dữ liệu trên biểu đồ Scatter Plot sẽ tùy thuộc vào bản chất của biến phụ thuộc. Nếu các điểm dữ liệu phân bố tập trung xung quanh đường tung độ 0 và có xu hướng tạo thành một đường thẳng thì giả định liên hệ tuyến tính không bị vi phạm.

Phương pháp này có một số ưu điểm so với các phương pháp trích chọn đặc trưng đã thảo luận ở phần trước, cụ thể như sau:

- Không cần xác định trước số lượng đặc trưng: Phương pháp xây dựng mô hình hồi quy đa biến loại bỏ yêu cầu xác định trước số lượng đặc trưng. Số lượng các đặc trưng hoàn toàn được xác định dựa trên tác động của chúng đến biến đầu ra trong mô hình. Điều này giải quyết hạn chế được thể hiện trong [5] và [33], trong đó điểm Fisher và phương pháp lựa chọn đặc trưng đơn biến được sử dụng yêu cầu một số lượng đặc trưng được xác định trước mà không có cơ sở khoa học.
- Khả năng diễn giải và thiết lập mối quan hệ: Bằng cách sử dụng mô hình hồi quy đa biến, quy trình đề xuất đề xuất đảm bảo thiết lập mối quan hệ rõ ràng giữa các đặc trưng và biến đầu ra trong khi vẫn duy trì khả năng diễn giải. Ngược lại, phương pháp KPCA được thảo luận trong [19] và thuật toán Relief-F cải tiến được nêu trong [1] gặp phải thách thức trong việc diễn giải mối quan hệ giữa các đặc trưng và biến đầu ra, cũng như mối quan hệ giữa chính các đặc trưng đó.
- Tính đơn giản và tính chính xác: Phương pháp trích chọn đặc trưng đề xuất tương đối đơn giản và tránh được sự cần thiết phải tinh chỉnh tham số mô hình một cách tỉ mỉ. Mô hình hồi quy thu được rất dễ diễn giải và phân tích. Những ưu điểm

này khắc phục được sự phức tạp liên quan đến việc hợp nhất hai thuật toán là ACO (ant colony optimization) và thuật toán RSA (reptile search algorithm) được trình bày trong [37]. Cách tiếp cận ACO-RSA rất phức tạp để thực hiện và yêu cầu điều chỉnh tham số tỉ mỉ.

- Xem xét các tương tác của đặc trưng: Phương pháp đề xuất tính đến sự tương tác lẫn nhau giữa các đặc trưng có ảnh hưởng đến biến đầu ra. Ngược lại, phương pháp lựa chọn đặc trưng đơn biến trong [33] chỉ xem xét tác động của từng biến riêng lẻ lên biến đầu ra. Rõ ràng là các biến số tương tác với nhau để dự đoán hành vi của khách hàng, khiến việc xây dựng mô hình hồi quy đa biến trở nên thuận lợi để nâng cao hiệu suất.
- Lưu giữ thông tin cần thiết: Phương pháp xây dựng mô hình hồi quy đa biến không tạo ra các đặc trưng mới và bất kỳ đặc trưng nào bị loại bỏ đều được chứng minh là không có tác động đến biến đầu ra. Do đó, các thông tin cần thiết được giữ lại, giảm thiểu hạn chế của các phương pháp tạo ra các đặc trưng mới, chẳng hạn như phương pháp KPCA [19] và phương pháp phân nhóm đồng khoảng cách (Equidistant Grouping) [48].

2.4. Xây dựng mô hình phân lớp hành vi khách hàng

Quá trình xây dựng mô hình phân lớp hành vi khách hàng được thực hiện trong luận văn tuân theo một quy trình cụ thể, bao gồm các bước: (1) Tối ưu hóa siêu tham số bằng cách sử dụng Tìm kiếm lưới. (2) Xác thực dữ liệu sử dụng kiểm thử chéo 10 lần và (3) Phân lớp hành vi khách hàng với các phương pháp học kết hợp đề xuất.

2.4.1. Tối ưu hóa siêu tham số

Theo nghiên cứu trước đó của Sana và cộng sự (2022) [33], trong quá trình thử nghiệm, luận văn áp dụng phương pháp Tìm kiếm lưới để tối ưu hóa các siêu tham số. Phương pháp Tìm kiếm lưới là một công cụ phổ biến và hiệu quả được sử dụng trong lĩnh vực học máy để tìm ra sự kết hợp tối ưu của các siêu tham số. Nó liên quan đến việc đánh giá toàn diện tất cả các kết hợp giá trị có thể có trong một phạm vi xác định. Áp dụng phương pháp này mang lại một số lợi thế quan trọng như sau:

- Tìm kiếm toàn diện: Tìm kiếm lưới xem xét tất cả các kết hợp có thể có của siêu tham số trong phạm vi được xác định, đảm bảo khám phá toàn diện không gian tham số.
- Triển khai dễ dàng: Việc triển khai Tìm kiếm lưới trong các khung, thư viện và ngôn ngữ lập trình khác nhau rất đơn giản.

- Không yêu cầu kiến thức trước: Tìm kiếm lưới không yêu cầu kiến thức chuyên môn hoặc kiến thức trước về các tham số mô hình, giúp các nhà nghiên cứu có mức độ kinh nghiệm khác nhau có thể sử dụng được.

2.4.2. Các phương pháp học kết hợp được đề xuất

Luận văn đã thực nghiệm các phương pháp học kết hợp được đề xuất với các mô hình phân lớp cơ sở được trình bày tại Hình 2.1. Các mô hình này bao gồm nhiều thuật toán khác nhau, bao gồm một thuật toán học máy truyền thống (LR), một thuật toán đóng bao (RF), bốn thuật toán tăng cường (Xgboost, Adaboost, Catboost và LightGBM) và hai thuật toán học sâu (CNN và FNN). Luận văn đề xuất hai phương pháp học kết hợp: xếp chồng và Voting. Dưới đây là mô tả của từng phương pháp:

- **Xếp chồng:** Luận văn thử nghiệm hai mô hình Xếp chồng:
 - Mô hình 1 (Hình 2.2): Mô hình này sử dụng tất cả tám mô hình phân lớp cơ sở được đề cập trong Hình 2.1. Sau đó, meta-model (Logistic Regression) đưa ra dự đoán dựa trên kết quả đầu ra của các mô hình phân lớp cơ sở này.
 - Mô hình 2: Mô hình này được mô tả tương tự như Hình 2.2, trong đó tám mô hình phân lớp cơ sở được thay thế bằng ba mô hình có hiệu suất tốt nhất. Meta-model được sử dụng cũng là Logistic Regression.

Ở đây, Logistic Regression (LR) trong phương pháp xếp chồng được sử dụng như một thuật toán phân lớp để dự đoán hành vi của khách hàng dựa trên khung dữ liệu bao gồm các trường dữ liệu là đầu ra của quá trình phân lớp đối với các thuật toán cơ sở. Mặc dù Logistic Regression thường được sử dụng để giải quyết bài toán hồi quy nhưng nó cũng có thể được áp dụng để thực hiện phân loại. Khía cạnh toán học của vấn đề này đã được minh họa trong phần 1.4.2.2.

Đối với 3 bộ dữ liệu có 2 nhãn 0 và 1 (Cell2cell, Bank và Campaign): Từ góc nhìn của bài toán phân loại, Logistic Regression có thể được xem như một mô hình phân loại nhị phân, trong đó đầu ra dự đoán là các xác suất thuộc về một lớp hoặc lớp còn lại.

Thuật toán Logistic Regression tính toán xác suất của một mẫu dữ liệu thuộc về một lớp cụ thể bằng cách sử dụng một hàm sigmoid để ánh xạ giá trị đầu vào sang một khoảng $[0, 1]$. Khi xác suất vượt qua một ngưỡng xác định, mẫu được dự đoán thuộc về lớp đó và ngược lại.

Trong phương pháp xếp chồng, Logistic Regression có thể được sử dụng như một bộ phân lớp cơ bản trong một tập hợp các bộ phân lớp đa dạng. Các bộ phân lớp này thường có các đặc điểm khác nhau như thuật toán, tham số, hoặc khung dữ liệu đào tạo. Bằng cách kết hợp các dự đoán của các bộ phân lớp này thông qua các quy tắc xếp

chồng, ta có thể tạo ra một mô hình mạnh hơn, có khả năng phân loại tốt hơn. Do đó, trong phương pháp xếp chồng, Logistic Regression có thể được sử dụng như một bộ phân lớp trong ensemble để thực hiện phân lớp.

Với bộ dữ liệu Customer shopping trends (6 nhãn), Logistic Regression sử dụng hàm Softmax để dự đoán đa nhãn. Hàm Softmax là một hàm số được sử dụng trong học máy và thống kê để chuyển đổi một tập hợp các số thực thành một phân phối xác suất. Hàm Softmax thường được sử dụng trong bài toán phân loại đa nhãn, trong đó mỗi mẫu dữ liệu có thể thuộc vào một trong nhiều nhãn khác nhau [31].

Với một vector đầu vào có giá trị thực, hàm Softmax tính toán một vector đầu ra có giá trị không âm trong đó các phần tử tổng lại thành 1. Quá trình này chuyển đổi các giá trị đầu vào thành các xác suất tương ứng cho mỗi nhãn.

Công thức tính toán hàm Softmax cho một vector đầu vào x có k phần tử là:

$$\text{softmax}(x_i) = \exp(x_i) / \sum(\exp(x_j)) \text{ for } j \in \text{range}(k) \quad (2.4)$$

Trong đó, $\exp(x_i)$ là hàm mũ tự nhiên (exponential function) của phần tử thứ i trong vector x . $\sum(\exp(x_j))$ là tổng của tất cả các hàm mũ trong vector x .

Hàm Softmax tạo ra một phân phối xác suất trên các nhãn khác nhau và thường được sử dụng làm hàm kích hoạt (activation function) cho lớp đầu ra cuối cùng trong mô hình phân loại đa nhãn như Logistic Regression với hàm Softmax (Multinomial Logistic Regression). Ở khía cạnh lập trình, để sử dụng hàm Softmax, tham số sau được đưa vào mô hình phân lớp Logistic Regression:: multi_class='multinomial' [31].


• **Bỏ phiếu:** Luận văn sử dụng ba cách tiếp cận Bỏ phiếu như sau:

- **Bỏ phiếu cứng:** Mỗi mô hình phân lớp cơ sở dự đoán độc lập kết quả rồi bỏ/mua hàng đối với một dữ liệu đầu vào nhất định và dự đoán cuối cùng được xác định bằng đa số phiếu bầu trong số các mô hình phân lớp cơ sở. Công thức bỏ phiếu cứng [18] được mô tả như sau:

$$\hat{y} = \arg \max_i \sum_{j=1}^N \mathbb{I}(y_{ij} = i) \quad (2.5)$$

Trong công thức (2.5):

- $\hat{y}$ là kết quả dự đoán cuối cùng, đại diện cho nhãn lớp được chọn bằng phương pháp bỏ phiếu cứng.
- Biểu thức $\arg \max_i$ là một phép toán được sử dụng để tìm ra giá trị i mà tổng sau cùng đạt giá trị lớn nhất. Trong trường hợp này, nó được sử dụng để tìm ra nhãn lớp i để tối đa hóa tổng sau.



Hình 2.2. Mô hình Xếp chồng đề xuất với tám thuật toán.

- N : tổng số bộ phân loại trong tập hợp.
- Tổng $\sum_{j=1}^N$ đại diện cho việc cộng các thành phần từ $j = 1$ đến N . Đây là tổng số phiếu của mỗi nhãn lớp dự đoán.
- $\mathbb{I}(y_{ij} = i)$ là một hàm chỉ báo có giá trị là 1 nếu dự đoán của bộ phân loại thứ j là nhãn lớp i , và 0 nếu ngược lại. Điều này đảm bảo rằng chỉ có các dự đoán đúng của từng bộ phân loại được tính vào tổng số phiếu.

Công thức (2.5) chọn nhãn lớp có số phiếu cao nhất làm dự đoán cuối cùng.

- **Bỏ phiếu mềm:** Mô hình phân lớp cơ sở cung cấp ước tính xác suất cho từng lớp và dự đoán cuối cùng được xác định bằng cách tính trung bình các xác suất trên tất cả các mô hình phân lớp cơ sở và chọn lớp có xác suất trung bình cao nhất. Công thức bỏ phiếu mềm [50] được mô tả như sau:

$$\hat{y} = \arg \max_i \sum_{j=1}^N p_{ij} \quad (2.6)$$

Trong công thức (2.6);

- $\hat{y}$ là kết quả dự đoán cuối cùng, đại diện cho nhãn lớp được chọn bằng phương pháp bỏ phiếu mềm.
- $\arg \max_i$ tìm ra giá trị i mà tổng sau cùng đạt giá trị lớn nhất. Trong trường hợp này, nó được sử dụng để tìm ra nhãn lớp i để tối đa hóa tổng sau.
- Tổng $\sum_{j=1}^N$ đại diện cho việc cộng các thành phần từ $j = 1$ đến N . Đây là

tổng trọng số dự đoán của mỗi mô hình phân loại.

- Thuật ngữ p_{ij} biểu thị xác suất dự đoán của lớp i bởi bộ phân loại j .

Công thức kết hợp các xác suất dự đoán từ tất cả các bộ phân loại và chọn nhãn lớp có xác suất tổng thể cao nhất làm dự đoán cuối cùng.

- **Bỏ phiếu có trọng số sử dụng *Evolutionary Algorithm***: Evolutionary Algorithm được sử dụng để tìm ra trọng số của các mô hình phân lớp cơ sở, giúp tối ưu hóa các trọng số để tối đa hóa hiệu suất của tập hợp. Dự đoán cuối cùng được xác định bằng cách kết hợp có trọng số các dự đoán của các mô hình phân loại cơ sở. Công thức của Voting có trọng số [13] được mô tả như sau:"

$$\hat{y} = \arg \max_i \sum_{j=1}^N w_j \cdot y_{ij} \quad (2.7)$$

Trong công thức (2.7):

- $\hat{y}$ là kết quả dự đoán cuối cùng, đại diện cho nhãn lớp được chọn bằng phương pháp voting có trọng số.

- $\arg \max_i$ được sử dụng để tìm ra giá trị i tạo ra tổng sau cùng lớn nhất. Trong trường hợp này, nó được sử dụng để tìm ra nhãn lớp i để tối đa hóa tổng sau.


- Tổng $\sum_{j=1}^N$ đại diện cho việc cộng các thành phần từ $j = 1$ đến N . Đây là tổng trọng số dự đoán của từng mô hình phân loại.

- Thuật ngữ w_j biểu thị trọng số được gán cho bộ phân loại j và y_{ij} đại diện cho nhãn lớp được dự đoán của bộ phân loại j chẳng hạn i .

Công thức tính tổng trọng số của các nhãn lớp được dự đoán từ tất cả các bộ phân loại, trong đó đóng góp của mỗi bộ phân loại được tính theo trọng số được chỉ định của nó. Nhãn lớp có tổng trọng số cao nhất được chọn làm dự đoán cuối cùng.

Mỗi cách tiếp cận voting đã trình bày được áp dụng trong hai trường hợp: Trường hợp thứ nhất áp dụng với tám mô hình phân lớp cơ sở được đề cập trong Hình 2.3. Trường hợp thứ hai được mô tả tương tự Hình 2.3, trong đó tám mô hình phân lớp cơ sở được thay thế bằng ba mô hình phân lớp hoạt động tốt nhất.

—> **Nhận xét:** Các phương pháp học kết hợp được đề xuất của luận văn đã giải quyết được khoảng trống nghiên cứu được xác định trước đó. Luận văn nâng cao việc lựa chọn mô hình phân lớp cơ sở bằng cách kết hợp một loạt thuật toán đa dạng, bao gồm thuật toán đơn lẻ, đóng bao, tăng cường và thuật toán học sâu. Những yếu tố đổi mới này làm nổi bật các phương pháp học kết hợp của luận văn và góp phần mang lại hiệu suất vượt trội so với các nghiên cứu trước đây.



Hình 2.3. Mô hình voting đề xuất với tám thuật toán.

2.5. Kiểm thử chéo, đưa ra kết quả và phân tích

Luận văn sử dụng phương pháp kiểm thử chéo (cross-validation) 10 lần để huấn luyện và kiểm tra các bộ phân lớp trong mô hình dự đoán hành vi khách hàng. Phương pháp này được sử dụng để đánh giá hiệu suất của mô hình một cách hiệu quả và tạo ra điều kiện so sánh công bằng với các nghiên cứu trước đó sử dụng cùng bộ dữ liệu.

Phương pháp kiểm thử chéo 10 lần là một quy trình quan trọng trong việc đánh giá hiệu suất của mô hình. Quá trình này chia dữ liệu thành 10 phần bằng nhau, sử dụng 9 phần để đào tạo mô hình và phần còn lại để kiểm tra. Quá trình này được lặp lại 10 lần, mỗi lần sử dụng một phần khác nhau để kiểm tra. Kết quả cuối cùng được tính toán dựa trên kết quả trung bình của các lần kiểm tra. Việc sử dụng kiểm thử chéo đem lại ưu điểm là đánh giá hiệu suất của mô hình một cách toàn diện và tránh tình trạng overfitting hoặc underfitting trên dữ liệu.

Thực hiện kiểm thử chéo 10 lần, luận văn trình bày chỉ số hiệu suất của mô hình và tiến hành phân tích bằng cách so sánh các phát hiện của luận văn với các nghiên cứu thực nghiệm trước đây trên các bộ dữ liệu tương tự.

Dựa vào khảo sát trước đó, trong trường hợp các bộ dữ liệu không cân bằng, chỉ số AUC thường được sử dụng để đánh giá hiệu suất của mô hình. Tuy nhiên, để thuận tiện trong việc so sánh với các nghiên cứu liên quan sử dụng cùng các bộ dữ liệu được sử dụng trong luận văn, luận văn cũng trình bày cả chỉ số F1 score và Accuracy cùng với AUC

(Đối với bộ dữ liệu có biến mục tiêu bao gồm đa lớp, các chỉ số tương ứng được trình bày là Micro-averaged F1, Micro-averaged Accuracy và Micro-averaged AUC). Thông qua việc đánh giá mô hình dự đoán với các chỉ số này, luận văn cung cấp cái nhìn tổng quan về hiệu suất và đồng thời dễ dàng so sánh với các nghiên cứu trước đây đã giải quyết bài toán dự đoán hành vi khách hàng.

Kết luận chương

Trong Chương Hai, luận văn đã trình bày chi tiết toàn bộ năm bước trong quy trình đề xuất để giải quyết bài toán dự đoán hành vi của khách hàng. Mô hình này đã được áp dụng trên bốn bộ dữ liệu khác nhau và kết quả chi tiết của quá trình áp dụng này được trình bày trong Chương tiếp theo.

CHƯƠNG 3

KỊCH BẢN VÀ KẾT QUẢ THỰC NGHIỆM

Chương Ba của luận văn trình bày kịch bản và kết quả thử nghiệm của mô hình dự đoán hành vi của khách hàng. Với các bước được đề cập trong quy trình đề xuất dự đoán hành vi khách hàng tại Chương Hai, các mục đích của quá trình thực nghiệm là:

(1) Chứng minh hiệu quả của quy trình đề xuất, trong đó bao gồm 2 khía cạnh chính: Quá trình tiền xử lý dữ liệu và phương pháp học kết hợp ứng dụng trong dự đoán hành vi khách hàng. Để đạt được mục đích này, hiệu suất mô hình phân lớp thu được từ quy trình đề xuất được so sánh với hiệu suất mô hình của các nghiên cứu đi trước sử dụng các bộ dữ liệu tương đương.

(2) Chứng minh tính linh hoạt của quy trình đề xuất trong dự đoán hiệu quả hành vi của khách hàng. Cụ thể, hai loại bài toán dự đoán hành vi khách hàng được đề cập, bao gồm dự đoán hành vi rời bỏ (tương ứng ba bộ dữ liệu Cell2cell, Campaign, Bank) và dự đoán xu hướng của hàng của khách hàng (bộ dữ liệu Customer Shopping Trends).

Quá trình nghiệm và kết quả thực nghiệm tương ứng được trình bày trong phần này bao gồm 3 nội dung: Tiền xử lý dữ liệu, Trích chọn đặc trưng và Kết quả xây dựng mô hình phân lớp hành vi khách hàng. Kết quả của mỗi nội dung trong quá trình thực nghiệm đều được so sánh với các nghiên cứu liên quan.

3.1. Kết quả tiền xử lý dữ liệu và so sánh với các nghiên cứu liên quan

3.1.1. Làm sạch dữ liệu

Sau khi xem xét ý nghĩa các đặc trưng của các bộ dữ liệu, dưới đây là các trường dữ liệu không cần thiết được xóa bỏ khỏi các bộ dữ liệu:

- Bộ dữ liệu Cell2cell: Xóa bỏ trường dữ liệu "Customer" (ID của khách hàng).
- Bộ dữ liệu Campaign: Giữ nguyên tất cả các trường dữ liệu.
- Bộ dữ liệu Bank: Xóa bỏ trường dữ liệu "CustomerId" (ID của khách hàng), "RowNumber" (Số hàng dữ liệu), "Surname" (Tên của khách hàng).
- Bộ dữ liệu Customer Shopping Trends: Xóa bỏ trường dữ liệu "CustomerId" (ID của khách hàng).

3.1.2. Xử lý dữ liệu phân loại

Dưới đây là các trường dữ liệu phân loại của các bộ dữ liệu đã được xử lý dựa trên phương pháp Label Encoding:

- Bộ dữ liệu Cell2cell: Không chứa các trường dữ liệu phân loại.

Bảng 3.1. Kết quả của một số bước trong quá trình tiền xử lý dữ liệu

Bộ dữ liệu	Chiến lược lấy mẫu	Số lượng đặc trưng	
		Ban đầu	Sau khi trích chọn đặc trưng
Cell2cell	0.75	71	39
Campaign	0.5	17	12
Bank	No Resampling	12	9
Customer Shopping Trends	No Resampling	17	8

– Bộ dữ liệu Campaign: Các trường dữ liệu phân loại bao gồm "job", "marital", "education", "default", "housing", "loan" sau khi áp dụng phương pháp Label Encoding đã chuyển từ dạng phân loại sang tương ứng 10, 6, 8, 2, 2, 2 số nguyên phân biệt.

– Bộ dữ liệu Bank: Các trường dữ liệu phân loại bao gồm "Geography", "Gender" sau khi áp dụng phương pháp Label Encoding đã chuyển từ dạng phân loại sang tương ứng 3, 2 số nguyên phân biệt.

– Bộ dữ liệu Customer Shopping Trends: Các trường dữ liệu phân loại bao gồm "Gender", "Item Purchased", "Category", "Location", "Size", "Color", "Season" sau khi áp dụng phương pháp Label Encoding đã chuyển từ dạng phân loại sang tương ứng 2, 5, 3, 5, 4, 5, 4 số nguyên phân biệt.

3.1.3. Xử lý dữ liệu mất cân bằng

Khi thử nghiệm với SMOTE, luận văn xem xét các tình huống khác nhau bằng cách điều chỉnh tham số "sampling strategy" thành các giá trị như 0,5, 0,75 và 1. Ngoài ra, luận văn cũng thực nghiệm với tùy chọn không thực hiện bất kỳ việc lấy mẫu lại nào và sau đó đã chọn phương pháp mang lại kết quả tốt nhất cho mỗi tập dữ liệu. Kết quả chiến lược lấy mẫu tối ưu với các bộ dữ liệu được thể hiện trong bảng 3.1.

3.1.4. So sánh các bước tiền xử lý dữ liệu của luận văn với một số nghiên cứu liên quan sử dụng cùng bộ dữ liệu

- **Bộ dữ liệu Cell2cell:** luận văn đã thực hiện quá trình tiền xử lý dữ liệu bằng các bước tương tự như được nêu trong nghiên cứu của nhóm tác giả Fujio và cộng sự (2022) [12]. Tuy nhiên, có những điểm khác biệt chính trong cách tiếp cận của luận văn:

– Phương pháp chuẩn hóa dữ liệu: Trong [12], MinMaxScaler đã được sử dụng, trong khi luận văn sử dụng StandardScaler. StandardScaler thường được coi là vượt trội hơn MinMaxScaler trong việc chuẩn hóa dữ liệu trước khi xây dựng mô hình hồi quy đa biến vì những lý do sau:

- * Bảo toàn thông tin phân phối: StandardScaler giữ lại các đặc trưng phân phối ban đầu của dữ liệu, điều này chứng tỏ có giá trị cho việc phân tích và diễn giải các kết quả của mô hình hồi quy.

* Khả năng tương thích với các thuật toán dựa trên độ dốc: Nhiều thuật toán hồi quy đa biến sử dụng phương pháp giảm độ dốc để tối ưu hóa. StandardScaler đảm bảo rằng các trường dữ liệu được cân bằng về độ lớn và được đưa vào cùng một phạm vi giá trị, từ đó tạo điều kiện cho thuật toán giảm độ dốc hội tụ nhanh hơn. Ngược lại, MinMaxScaler có thể gây ra sự mất cân bằng về cường độ trường dữ liệu, dẫn đến quá trình tối ưu hóa chậm hơn.

• **Bộ dữ liệu Campaign:** So với hai nghiên cứu gần đây đạt được hiệu suất tốt trên tập dữ liệu mà luận văn đã đánh giá, phương pháp tiền xử lý dữ liệu của luận văn khác nhau ở một số khía cạnh:

– So sánh với Geiler và cộng sự [14] (2022): Trong khi Geiler và cộng sự [14] (2022) chỉ tập trung vào việc so sánh các kỹ thuật lấy mẫu dữ liệu (Oversampling, Undersampling và Hybrid), quá trình xử lý trước dữ liệu của luận văn bao gồm sáu bước riêng biệt. Đóng góp của các tác giả trong việc giải quyết vấn đề mất cân bằng dữ liệu là có giá trị. Tuy nhiên, quy trình tiền xử lý dữ liệu của họ trước khi tiến hành lấy mẫu dữ liệu không được chú trọng, có khả năng ảnh hưởng đến hiệu suất của mô hình. Bộ dữ liệu của luận văn chứa các trường dữ liệu phân loại có thể được xử lý và cần xem xét số lượng trường dữ liệu được sử dụng trong quá trình phân loại. Một số trường dữ liệu có thể ít ảnh hưởng đến nhiệm vụ phân loại và có thể được loại bỏ, giảm thời gian tính toán. Trong nghiên cứu của luận văn và nghiên cứu của Obiedat [28], một số trường dữ liệu nhất định đã bị loại bỏ trong quá trình thử nghiệm trên tập dữ liệu này.

• **Bộ dữ liệu Bank:** Mô hình của luận văn thể hiện một số lợi thế khác biệt khi so sánh với các phương pháp tiếp cận được nêu bật trong nghiên cứu của Geiler và cộng sự [14] (2022), Tekouabou và cộng sự [43] (2022) và Elyusufi [10] (2022):

– Xử lý trường dữ liệu phân loại: Trong khi Tekouabou và cộng sự và Elyusufi đã sử dụng nhiều kỹ thuật khác nhau để biến đổi dữ liệu phân loại, việc sử dụng mã hóa nhãn để xử lý dữ liệu phân loại trong mô hình của luận văn đặc biệt thuận lợi, đặc biệt đối với các tập dữ liệu có số lượng lớn trường dữ liệu. Mã hóa một lần, như được sử dụng trong một số phương pháp tiếp cận, có thể dẫn đến sự gia tăng đáng kể về số lượng trường dữ liệu, làm cho mã hóa nhãn trở thành lựa chọn hiệu quả hơn cho các bộ dữ liệu đó.

– Lấy mẫu lại: Không giống như một số phương pháp được đề cập [10, 43] khám phá các kỹ thuật lấy mẫu lại như SMOTE, mô hình của luận văn đã chứng minh thông qua thử nghiệm rộng rãi rằng việc không sử dụng các phương

pháp lấy mẫu lại mang lại hiệu suất cao nhất. Điều này nhấn mạnh khả năng mô hình của luận văn tận dụng các đặc tính nội tại của chính tập dữ liệu, hợp lý hóa các bước tiền xử lý và có khả năng giảm độ phức tạp tính toán.

- **Bộ dữ liệu Online Shopping Trends:** Online Shopping Trends được sử dụng làm dữ liệu thử nghiệm trong các nghiên cứu do các tác giả Abdulsalam và cộng sự thực hiện trong [1] (2022). Nghiên cứu này sử dụng một bước tiền xử lý dữ liệu duy nhất, đó là trích chọn đặc trưng với thuật toán Relief-F cải tiến. Sự so sánh này sẽ được trình bày cụ thể trong phần sau.

Nhìn chung, phương pháp tiền xử lý của luận văn sử dụng các kỹ thuật tiên tiến ở mỗi bước để nâng cao chất lượng của tập dữ liệu, giải quyết các thách thức chung về lập mô hình và cuối cùng là cải thiện hiệu suất cũng như độ tin cậy của các mô hình dự đoán. Nó phản ánh cách tiếp cận có hệ thống và dựa trên dữ liệu để xây dựng các mô hình dự đoán hành vi khách hàng.

3.2. Kết quả trích chọn đặc trưng và so sánh với các nghiên cứu liên quan sử dụng cùng bộ dữ liệu


3.2.1. Kết quả trích chọn đặc trưng của các bộ dữ liệu

Số lượng đặc trưng trước và sau khi áp dụng phương pháp xây dựng mô hình hồi quy đa biến của các bộ dữ liệu thực nghiệm trong luận văn được thể hiện trong bảng 3.1. Nhận thấy, phương pháp trích chọn đặc trưng được sử dụng không những giải quyết được những hạn chế của các phương pháp trích chọn đặc trưng khác mà còn có tác dụng giảm số lượng đặc trưng từ đó giảm thời gian tính toán.


Bên cạnh việc trích xuất các đặc trưng có mặt trong mô hình hồi quy đa biến, luận văn sử dụng biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình. Bốn biểu đồ Scatter tương ứng bốn bộ dữ liệu được thực nghiệm trong luận văn được trình bày từ Hình 3.1 đến Hình 3.4. Nhận thấy, các điểm dữ liệu trong các biểu đồ Scatter đều có dạng các đường thẳng song song, như vậy giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình của các bộ dữ liệu không bị vi phạm.

3.2.2. So sánh kỹ thuật trích chọn đặc trưng của luận văn với một số nghiên cứu liên quan


- **Bộ dữ liệu Cell2cell:** Như đã đề cập trước đó, phương pháp của luận văn mang lại lợi thế hơn phương pháp Hồi quy Lasso đã áp dụng trên bộ dữ liệu Cell2cell trong [12] (2022) do không yêu cầu lựa chọn trước một số đặc trưng cụ thể quan trọng nhất. Ngược lại, phương pháp Hồi quy Lasso chỉ tùy ý chọn ra 10 đặc trưng hàng đầu mà không có cơ sở khoa học chứng minh cho sự lựa chọn đó. Ngoài ra, việc chỉ chọn 10 đặc trưng có thể khiến các đặc trưng quan trọng bị bỏ qua. Trong thử




Hình 3.1. Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Cell2cell.



Hình 3.2. Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Campaign.



Hình 3.3. Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Bank.



Hình 3.4. Biểu đồ Scatter kiểm tra giả định liên hệ tuyến tính giữa biến phụ thuộc và các đặc trưng trong mô hình đối với bộ dữ liệu Customer shopping trends.

nghiệm của luận văn, phương pháp xây dựng mô hình hồi quy đa biến đã chọn lọc và giữ lại 39 đặc trưng cho quá trình phân loại.

- **Bộ dữ liệu Campaign:** Trong khi nhóm tác giả Obiedat và cộng sự [28] (2020) chỉ tập trung vào việc trích chọn đặc trưng như một bước tiền xử lý. Cụ thể, họ đã sử dụng tùy chọn phân loại meta và tab thuộc tính chọn trong công cụ Weka để chọn 5, 10 và 15 đặc trưng hàng đầu. Tuy nhiên, những con số này được chọn không có cơ sở khoa học và việc thử nghiệm cả ba trường hợp để xác định số lượng đặc trưng tối ưu cần có thời gian đáng kể. Ngược lại, nghiên cứu của luận văn đã tiến hành trích xuất đặc trưng trước đó và xác định được 12 đặc trưng để xây dựng mô hình phân loại. Ngoài ra, bộ dữ liệu Campaign được sử dụng trong nghiên cứu của luận văn bị mất cân bằng và luận văn đã sử dụng kỹ thuật SMOTE để giải quyết vấn đề mất cân bằng dữ liệu, trong khi các tác giả trong [28] không sử dụng bất kỳ kỹ thuật nào để xử lý vấn đề này.
- **Bộ dữ liệu Bank:** Với bộ dữ liệu Bank, phương pháp trích chọn đặc trưng của luận văn có cách tiếp cận tương tự như cách tiếp cận của Elyusufi [10] (2022) bao gồm việc chọn các đặc trưng dựa trên mức độ liên quan của chúng với biến dự đoán rời bỏ. Tuy nhiên, mô hình của luận văn tiến thêm một bước bằng cách sử dụng mô hình hồi quy đa biến. Cách tiếp cận này mang lại một số lợi thế, bao gồm khả năng diễn giải, thiết lập các mối quan hệ biến đặc trưng rõ ràng và xem xét các tương tác đặc trưng. Hơn nữa, luận văn đảm bảo các đặc trưng được chọn không có mối tương quan cao với nhau bằng cách đánh giá đa cộng tuyến bằng cách sử dụng các giá trị Hệ số lạm phát phương sai (VIF). Điều này nâng cao tính mạnh mẽ và độ tin cậy tổng thể của mô hình của luận văn.
- **Bộ dữ liệu Online Shopping Trends:** Nhóm tác giả Abdulsalam và cộng sự trong [1] (2022) đã thực hiện trích chọn đặc trưng với thuật toán Relief-F cải tiến. Phương pháp này có hạn trong việc diễn giải mối quan hệ giữa các đặc trưng và biến đầu ra, cũng như mối quan hệ giữa chính các đặc trưng đó. Trong khi phương pháp trích chọn đặc trưng được sử dụng trong luận văn, thông qua xây dựng mô hình hồi quy đa biến giúp dễ dàng diễn giải mối quan hệ giữa các đặc trưng và biến đầu ra. Điều này có thể cung cấp cái nhìn sâu hơn và giải thích được sự ảnh hưởng của các đặc trưng đến biến đầu ra.

3.3. Kết quả xây dựng mô hình phân lớp hành vi khách hàng và so sánh với các nghiên cứu liên quan

3.3.1. Kết quả tối ưu hóa siêu tham số

Trước khi xây dựng mô hình phân lớp hành vi khách hàng, luận văn sử dụng kỹ thuật tìm kiếm lưới để tối ưu hóa siêu tham số cho các bộ phân loại. Kết quả siêu tham

số tối ưu của các bộ phân lớp được trình bày tại Bảng 3.2.

Bảng 3.2. Siêu tham số của các mô hình phân lớp

Classifier	Campaign	Cell2cell	Bank	Customer Shopping Trends
LR	C: 7, multi_class: ovr, penalty: 11, solver: liblinear	C: 1, multi_class: ovr, penalty: 11, solver: liblinear	C: 1, multi_class: ovr, penalty: 11, solver: liblinear	C: 7, multi_class: ovr, penalty: 11, solver: newton-cg
RF	bootstrap: True, max_depth: 100, max_features: 3, min_samples_leaf: 3, min_samples_split: 12, n_estimators: 1000	bootstrap: True, max_depth: 100, max_features: 3, min_samples_leaf: 3, min_samples_split: 12, n_estimators: 1000	bootstrap: True, max_depth: 100, max_features: 3, min_samples_leaf: 5, min_samples_split: 12, n_estimators: 1000	bootstrap: True, class_weight: None, criterion: entropy, max_depth: 100, min_samples_leaf: 4, min_samples_split: 10, n_estimators: 100, n_jobs: None
XGBoost	learning_rate: 0.2, max_depth: 7, n_estimators: 500, random_state: 10	learning_rate: 0.2, max_depth: 7, n_estimators: 500, random_state: 10	learning_rate: 0.1, max_depth: 7, n_estimators: 500, random_state: 10	learning_rate: 0.1, max_depth: 4, n_estimators: 100, random_state: 10
AdaBoost	learning_rate: 1.0, n_estimators: 500	learning_rate: 1.0, n_estimators: 500, random_state: 10	learning_rate: 1.0, n_estimators: 500	learning_rate: 1.0, n_estimators: 500
CatBoost	depth: 4, iterations: 200, learning_rate: 0.05, random_state: 10	depth: 4, iterations: 200, learning_rate: 0.05, random_state: 10	depth: 8, iterations: 200, learning_rate: 0.1, random_state: 10	depth: 4, iterations: 200, learning_rate: 0.05, random_state: 10
LightGBM	boosting_type: gbdt, feature_fraction: 0.5, learning_rate: 0.1, min_data_in_leaf: 50, num_leaves: 100	boosting_type: gbdt, feature_fraction: 0.5, learning_rate: 0.1, min_data_in_leaf: 50, num_leaves: 100	boosting_type: gbdt, feature_fraction: 1.0, learning_rate: 0.1, min_data_in_leaf: 10, num_leaves: 100	boosting_type: gbdt, feature_fraction: 0.5, learning_rate: 0.1, min_data_in_leaf: 50, num_leaves: 100
FNN	epochs: 10, batch_size: 20	epochs: 10, batch_size: 20	epochs: 10, batch_size: 40	epochs: 10, batch_size: 40
CNN	epochs: 10, batch_size: 80	epochs: 10, batch_size: 90	epochs: 10, batch_size: 80	epochs: 10, batch_size: 40

3.3.2. Kết quả hiệu suất mô hình phân lớp hành vi khách hàng và phân tích kết quả

Luận văn đã áp dụng các mô hình phân lớp đề xuất được mô tả trong Hình 2.1. Các kết quả đã chứng minh hiệu quả của phương pháp học kết hợp so với phần lớn các mô hình cơ sở. Hiệu suất tối ưu đạt được thông qua bỏ phiếu cứng, sử dụng ba thuật toán hàng đầu làm mô hình cơ sở và tối ưu hóa trọng số phân loại bằng thuật toán tiến hóa. Các kết quả, bao gồm điểm AUC và F1 cho tất cả tám thuật toán và hiệu suất của các mô hình học kết hợp sử dụng tất cả tám thuật toán và ba thuật toán hiệu suất cao nhất,

được trình bày trong Bảng 3.3 và Bảng 3.4. Thông qua các bảng kết quả này, nhận thấy phương pháp Hard Voting có trọng số luôn là phương pháp cho hiệu suất tốt nhất khi so sánh với các phương pháp được thực nghiệm trong luận văn.

Bảng 3.3. Độ đo AUC của các mô hình phân lớp

Dataset	LR	RF	XgBoost	AdaBoost	CatBoost	LightGBM	FNN	CNN	S1 ⁵	S2 ⁶	V1_Hard ⁷	V2_Hard ⁸	V1_Soft ⁹	V2_Soft ¹⁰
Campaign	91.71%	93.39%	91.68%	91.21%	93.37%	92.67%	91.88%	93.05%	92.76%	93.9%	93.56%	94.82%	93.56%	94.62%
Cell2Cell	84.32%	84.02%	84.86%	85.45%	84.50%	85.45%	82.80%	83.08%	84.74%	85.72%	85.95%	86.82%	85.95%	86.82%
Bank	86.04%	86.16%	84.87%	85.47%	85.49%	85.55%	85.27%	86.36%	85.92%	86.82%	86.98%	87.81%	86.98%	87.81%
Customer Shopping Trends	86.23%	87.29%	86.34%	86.82%	87.90%	87.93%	86.16%	86.77%	87.74%	87.95%	87.48%	88.24%	88.05%	87.92%

Bảng 3.4. Độ đo F1 của các mô hình phân lớp

Dataset	LR	RF	XgBoost	AdaBoost	CatBoost	LightGBM	FNN	CNN	S1	S2	V1_Hard	V2_Hard	V1_Soft	V2_Soft
Campaign	63.58%	64.91%	63.80%	63.17%	65.34%	64.06%	63.92%	64.22%	64.29%	65.80%	67.48%	68.29%	66.51%	67.50%
Cell2Cell	75.26%	76.64%	76.86%	76.94%	75.94%	76.89%	73.34%	73.75%	76.07%	77.82%	79.18%	79.99%	78.33%	78.93%
Bank	81.22%	85.24%	85.07%	84.14%	84.72%	85.55%	83.55%	86.16%	84.72%	86.52%	88.03%	89.11%	87.51%	88.22%
Customer Shopping Trends	77.23%	78.30%	78.92%	77.03%	79.75%	79.28%	77.42%	77.94%	78.19%	78.54%	78.25%	80.22%	79.21%	79.73%

⁵Xếp chồng sử dụng 8 mô hình phân lớp cơ sở.

⁶Xếp chồng sử dụng 3 mô hình phân lớp có hiệu suất tốt nhất.

⁷Bỏ phiếu cứng sử dụng 8 mô hình phân lớp cơ sở.

⁸Bỏ phiếu cứng 3 mô hình phân lớp có hiệu suất tốt nhất..

⁹Bỏ phiếu mềm sử dụng 8 mô hình phân lớp cơ sở.

¹⁰Bỏ phiếu mềm 3 mô hình phân lớp có hiệu suất tốt nhất.

Bảng 3.5. So sánh hiệu suất mô hình giữa luận văn và các nghiên cứu trước đây

Bộ dữ liệu	Metric	Hiệu suất tốt nhất		Mức chênh lệch
		Luận văn	Nghiên cứu trước đây	
Campaign	AUC	94.82%	94.4% [14]	0.42%
	F1	68.29%	59.2% [28]	9.09%
	ACC	92.56%	91.44% [28]	1.12%
Cell2cel	AUC	86.82%	73.9% [12]	12.92%
	F1	79.99%	77.47% [12]	2.52%
	ACC	78.23%	73.9% [12]	4.33%
Bank	AUC	87.81%	85.83% [14]	1.98%
	F1	89.11%	86.0% [43]	3.11%
	ACC	90.05%	89.09% [10]	0.98%
Customer Shopping Trends	AUC	88.24%	—	—
	F1	80.22%	77.53% [1]	2.69%
	ACC	95.25%	93.88% [1]	1.37%

Luận văn đạt hiệu suất tốt hơn nghiên cứu trước đó thông quan việc sử dụng phương pháp được thiết kế tỉ mỉ mang lại độ chính xác dự đoán vượt trội trong dự đoán hành vi của khách hàng. Mô hình của luận văn luôn vượt trội so với những nỗ lực trước đây về các số liệu như AUC, điểm F1 và ACC, chứng tỏ tính hiệu quả của nó trong việc dự đoán chính xác hành vi của khách hàng. Các kết quả so sánh được tóm tắt trong Bảng 3.5, cung cấp cái nhìn tổng quan về những so sánh hiệu suất này. Kết quả này đồng thời chứng minh được tính linh hoạt của quy trình đề xuất khi dự đoán thành công cả hành vi rời bỏ và tần suất mua hàng của khách hàng, trong khi các nghiên cứu trước đây thường chỉ tập trung vào một trong những hành vi này. Bảng 3.5 cho thấy việc sử dụng phương pháp bỏ phiếu cứng đảm bảo sự đồng thuận hài hòa giữa các mô hình cơ sở và nâng cao độ chính xác của dự đoán tổng thể. Trong bối cảnh nghiên cứu cạnh tranh, phương pháp học kết hợp được sử dụng trong luận văn được chứng minh là một giải pháp hiệu quả để dự đoán hành vi khách hàng.

Các bộ dữ liệu Cell2cell, Campaign và Bank, nhằm nắm bắt hành vi rời bỏ của khách hàng ban đầu được giới thiệu bởi Geiler và cộng sự trong công trình thử nghiệm của họ [14] (2022). Tương tự như nghiên cứu của luận văn, nhóm tác giả Geiler và cộng sự [14] đã sử dụng các kỹ thuật học kết hợp để dự đoán tỷ lệ rời bỏ. Tuy nhiên, cách tiếp cận của họ chỉ tập trung vào bỏ phiếu mềm, trong đó xác suất dự đoán từ các mô hình LR, XGBoost, RF và Mạng thần kinh được tính trung bình cho từng trường hợp, xem xét hai, ba hoặc bốn phương pháp. Trong khi đó, luận văn sử dụng phương pháp học kết hợp toàn diện hơn, với các phương pháp xếp chồng, bỏ phiếu cứng, bỏ phiếu mềm và bỏ phiếu theo trọng số để xác định kỹ thuật thực hiện tối ưu. Cách tiếp cận của luận văn mang lại kết quả đáng kể, thể hiện các số liệu hiệu suất vượt trội so với kết quả của Geiler và cộng sự (được trình bày cụ thể trong Bảng 3.5). Điều này nêu bật tính hiệu quả của việc ấn định trọng số thích hợp cho các thuật toán cấu thành của phương pháp bỏ phiếu. Hơn nữa, nghiên cứu của luận văn bao gồm nhiều thuật toán tăng cường, đóng

bao và học sâu hơn so với các tác giả, cho phép luận văn chọn ba thuật toán hoạt động tốt nhất góp phần nâng cao hiệu suất của mô hình tổng hợp của luận văn.

Ngoài Geiler và cộng sự [14] (2022), Fujio và cộng sự [12] (2022) cũng đã nghiên cứu **bộ dữ liệu Cell2cell** nhưng họ chỉ sử dụng mô hình deep-BP-ANN. Trong khi luận văn thực hiện kết hợp các thuật toán tăng cường, đóng bao và học sâu. **Mô hình của luận văn hoạt động tốt hơn mô hình của nhóm tác giả Fujio và cộng sự [12], với mức cải thiện 12,92% về AUC, 2,52% về điểm F1 và 4,53% về Độ chính xác.** Sự thành công trong phương pháp của luận văn có thể là nhờ sự kết hợp của nhiều thuật toán cơ bản khác nhau như tăng cường, đóng bao và học sâu, trong khi Fujio và cộng sự [12] chỉ dựa vào học sâu. Bằng cách tận dụng nhiều thuật toán, luận văn khai thác ưu điểm của từng thuật toán, dẫn đến giảm tình trạng trang bị quá mức và tăng tính tổng quát hóa mô hình. Hơn nữa, phương pháp học kết hợp của luận văn cho thấy độ ổn định cao hơn so với mô hình deep-BP-ANN. Sự hợp nhất của nhiều mô hình giúp giảm thiểu tác động của dữ liệu nhiễu và biến động dự đoán, mang lại những dự đoán nhất quán và đáng tin cậy hơn trên bộ dữ liệu Cell2cell.

Phương pháp học kết hợp của luận văn một lần nữa đã chứng tỏ tính hiệu quả vượt trội so với các thuật toán đơn lẻ khác khi áp dụng với **bộ dữ liệu Campaign**. Obiedat [28] (2020) đã tiến hành thử nghiệm bằng thuật toán cây quyết định với bộ dữ liệu này. Thông qua việc kết hợp nhiều thuật toán thay vì chỉ sử dụng một thuật toán duy nhất như trong nghiên cứu của tác giả Obiedat [28], **các chỉ số F1 và độ chính xác trong luận văn đã có sự cải thiện hơn, tương ứng 3.11% và 0.98%.**

Với bộ dữ liệu Bank, Elyusufi và cộng sự [10] (2022) và Tékouabou và cộng sự [43] (2022) đã sử dụng nhiều thuật toán khác nhau, bao gồm tăng cường, đóng bao và học sâu. Tuy nhiên, phương pháp học kết hợp của luận văn vượt trội hơn các thuật toán này bằng cách kết hợp các điểm mạnh của thuật toán tăng cường, đóng bao và học sâu trong quá trình phân loại (xem Bảng 3.5). Bằng cách tích hợp các mô hình đa dạng này, phương pháp tiếp cận của luận văn giới thiệu tính đa dạng của mô hình và thu thập được nhiều mẫu dữ liệu hơn, dẫn đến dự đoán được cải thiện so với chỉ sử dụng một thuật toán duy nhất. Hơn nữa, phương pháp tập hợp làm giảm độ biến thiên dự đoán và nâng cao độ tin cậy của kết quả của luận văn.

Abdulsalam và cộng sự [1] (2022) đã tiến hành nghiên cứu sử dụng **bộ dữ liệu Customer Shopping Trends** với các thuật toán Random Forest, Gradient Boosted tree, KNN, Naive Bayes, Kernel Naive Bayes, và Neural Network. Tuy nhiên, quy trình đề xuất của luận văn áp dụng học kết hợp, sử dụng một số thuật toán mà nhóm tác giả sử dụng với vai trò là mô hình học máy cơ sở. **Cách tiếp cận của luận văn đã dẫn đến các chỉ số hiệu suất tăng đều đặn khoảng hơn 2% đối với cả 3 chỉ số Accuracy, AUC và F1.**

Kết luận chương

Trong chương 3, luận văn đã trình bày chi tiết kịch bản thực nghiệm và kết quả thực nghiệm tương ứng của toàn bộ các bước trong quy trình đề xuất để giải quyết bài toán dự đoán hành vi của khách hàng. Mô hình này đã được áp dụng trên bốn bộ dữ liệu khác nhau thuộc hai loại bài toán dự đoán hành vi khách hàng: Dự đoán rời bỏ và dự đoán tần suất mua hàng của khách hàng từ đó chứng minh được tính linh hoạt hiệu quả và của quy trình đề xuất khi so sánh với các nghiên cứu trước đây.

KẾT LUẬN

Luận văn đã đạt được đóng góp đề ra ban đầu trong giải quyết bài toán dự đoán hành vi khách hàng. Đầu tiên, luận văn đã phát triển một mô hình linh hoạt cho việc dự đoán đồng thời tần suất mua hàng và hành vi rời bỏ của khách hàng. Điều này mang lại giá trị lớn cho doanh nghiệp, giúp họ nắm bắt được xu hướng và động lực của khách hàng, từ đó áp dụng các chiến lược tiếp thị và quản lý khách hàng hiệu quả hơn.

Thứ hai, luận văn đã giới thiệu một phương pháp trích chọn đặc trưng mới và hiệu quả thông qua hồi quy đa biến. Phương pháp này đã giúp xác định một cách chính xác các yếu tố quan trọng ảnh hưởng đến hành vi của khách hàng. Điều này không chỉ cải thiện hiệu suất dự đoán mà còn cung cấp hiểu biết sâu sắc về các yếu tố quyết định hành vi rời bỏ và tần suất mua hàng của khách hàng.

Cuối cùng, luận văn đã tích hợp các thuật toán học kết hợp và học sâu vào mô hình dự đoán. Sự kết hợp này đã nâng cao khả năng của mô hình trong việc xử lý dữ liệu phức tạp và đưa ra dự đoán chính xác với độ chính xác cao hơn so với các nghiên cứu đi trước. Cụ thể:

- Đối với tập dữ liệu Campaign: AUC và F1 cao hơn tương ứng 0.42% và 9.09% so với nghiên cứu đi trước;
- Đối với tập dữ liệu Cell2Cell, AUC và F1 cao hơn tương ứng 12.92% và 2.52% so với nghiên cứu đi trước;
- Đối với tập dữ liệu Bank, AUC và F1 cao hơn tương ứng 1.98% và 3.11% so với nghiên cứu đi trước;
- Đối với tập dữ liệu Customer Shopping Trends, F1 cao hơn 2.69% so với nghiên cứu đi trước.

Trong công việc tương lai, luận văn có thể được mở rộng bằng cách khám phá thêm những vấn đề dự đoán hành vi khách hàng bổ sung và áp dụng khung đề xuất của luận văn để mở rộng tính linh hoạt và khả năng áp dụng của nó. Ngoài ra, có thể tích hợp các kỹ thuật phân tích mạng xã hội từ đó nắm bắt được ảnh hưởng của các mối quan hệ xã hội đối với quyết định của khách hàng. Một công việc tương lai có tiềm năng khác là khám phá một phương pháp kết hợp nhiều giai đoạn để cải thiện hiệu suất dự đoán hành vi khách hàng.

TÀI LIỆU THAM KHẢO

- [1] Abdulsalam, S. O. et al., “Customer Churn Prediction in Telecommunication Industry Using Classification and Regression Trees and Artificial Neural Network Algorithms”, *Indonesian Journal of Electrical Engineering and Informatics (IJEI)* 10.2 (2022-06-12), pp. 431–440, ISSN: 2089-3272, 2089-3272, DOI: 10.52549/ijeii.v10i2.2985, URL: <http://section.iaesonline.com/index.php/IJEI/article/view/2985>.
- [2] AL-Najjar, D., Al-Rousan, N., and AL-Najjar, H., “Machine Learning to Develop Credit Card Customer Churn Prediction”, *Journal of Theoretical and Applied Electronic Commerce Research* 17.4 (2022), Publisher: MDPI, pp. 1529–1542.
- [3] Amin, A. et al., “Cross-company customer churn prediction in telecommunication: A comparison of data transformation methods”, *International Journal of Information Management* 46 (2019), Publisher: Elsevier, pp. 304–319.
- [4] Barton, M. and Lennox, B., “Model stacking to improve prediction and variable importance robustness for soft sensor development”, *Digital Chemical Engineering* 3 (June 1, 2022), p. 100034, ISSN: 2772-5081, DOI: 10.1016/j.dche.2022.100034, URL: <https://www.sciencedirect.com/science/article/pii/S2772508122000254>.
- [5] Bogaert, M. and Delaere, L., “Ensemble Methods in Customer Churn Prediction: A Comparative Analysis of the State-of-the-Art”, *Mathematics* 11.5 (2023), Publisher: MDPI, p. 1137.
- [6] *Classification: objectives and metrics*, URL: <https://catboost.ai/en/docs/concepts/loss-functions-classification> (visited on 11/30/2023).
- [7] Dalli, A., “Impact of hyperparameters on deep learning model for customer churn prediction in telecommunication sector”, *Mathematical Problems in Engineering* 2022 (2022), Publisher: Hindawi.
- [8] De, S. and Prabu, P., “A Representation-Based Query Strategy to Derive Qualitative Features for Improved Churn Prediction”, *IEEE Access* 11 (2023), Conference Name: IEEE Access, pp. 1213–1223, ISSN: 2169-3536, DOI: 10.1109/ACCESS.2022.3233768.
- [9] Elgohary, E. M. et al., “Smart evaluation for deep learning model: churn prediction as a product case study”, *Bulletin of Electrical Engineering and Informatics* 12.2 (2023), pp. 1219–1225.
- [10] ELYUSUFI, Y. and KBIR, M. A., “Churn Prediction Analysis by Combining Machine Learning Algorithms and Best Features Exploration”, *International Journal of Advanced Computer Science and Applications* 13.7 (2022), DOI: 10.14569/ijacsa.2022.0130773, URL: <https://doi.org/10.14569/ijacsa.2022.0130773>.

- [11] Fávero, L. P., Belfiore, P., and Freitas Souza, R. de, “Chapter 20 - Boosting and bagging”, *Data Science, Analytics and Machine Learning with R*, ed. by Fávero, L. P., Belfiore, P., and Freitas Souza, R. de, Academic Press, Jan. 1, 2023, pp. 403–427, ISBN: 978-0-12-824271-1, DOI: 10.1016/B978-0-12-824271-1.00017-2, URL: <https://www.sciencedirect.com/science/article/pii/B9780128242711000172>.
- [12] Fujo, S. W., Subramanian, S., and Khder, M. A., “Customer Churn Prediction in Telecommunication Industry Using Deep Learning”, *Information Sciences Letters* 11.1 (2022-01-01), pp. 185–198, ISSN: 20909551, 2090956X, DOI: 10.18576/isl/110120, URL: <http://www.naturalspublishing.com/Article.asp?ArtcID=24434>.
- [13] García-Martínez, C., Cordon, O., and Herrera, F., “A taxonomy and an empirical analysis of multiple objective ant colony optimization algorithms for the bi-criteria TSP”, *European Journal of Operational Research* 180.1 (2007-07), pp. 116–148, ISSN: 03772217, DOI: 10.1016/j.ejor.2006.03.041, URL: <https://linkinghub.elsevier.com/retrieve/pii/S0377221706002451>.
- [14] Geiler, L., Affeldt, S., and Nadif, M., “A survey on machine learning methods for churn prediction”, *International Journal of Data Science and Analytics* 14.3 (2022-09), pp. 217–242, ISSN: 2364-415X, 2364-4168, DOI: 10.1007/s41060-022-00312-5, URL: <https://link.springer.com/10.1007/s41060-022-00312-5>.
- [15] Goodfellow, I., Bengio, Y., and Courville, A., *Deep Learning*, Google-Books-ID: Np9SDQAAQBAJ, MIT Press, Nov. 18, 2016, 801 pp., ISBN: 978-0-262-03561-3.
- [16] *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd Edition [Book]*, ISBN: 9781492032649, URL: <https://www.oreilly.com/library/view/hands-on-machine-learning/9781492032632/>.
- [17] Haridasan, V., Muthukumaran, K., and Hariharanath, K., “Arithmetic Optimization with Deep Learning Enabled Churn Prediction Model for Telecommunication Industries.”, *Intelligent Automation & Soft Computing* 35.3 (2023).
- [18] Hastie, T., Tibshirani, R., and Friedman, J., *The Elements of Statistical Learning*, Springer Series in Statistics, New York, NY: Springer, 2009, ISBN: 978-0-387-84857-0 978-0-387-84858-7, DOI: 10.1007/978-0-387-84858-7, URL: <http://link.springer.com/10.1007/978-0-387-84858-7>.
- [19] Hooda, P. and Mittal, P., “IMPLEMENTATION AND PERFORMANCE ENHANCEMENTS OF OPTIMISED KERNEL MSVM MODEL FOR EARLY CHURN PREDICTION IN TELECOM SECTOR”, *Semiconductor Optoelectronics* 42.1 (2023), pp. 280–298.
- [20] Jajam, N. and Challa, N. P., “Customer Churn Detection for insurance data using Blended Logistic Regression Decision Tree Algorithm (BLRDT)”, *International Journal of Intelligent Systems and Applications in Engineering* 11.1 (2023), pp. 72–83.

- [21] Ke, G. et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”, *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017, URL: <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html> (visited on 09/14/2023).
- [22] Kotler, P. and Armstrong, G., *Principles of marketing*, 5th ed, Prentice-Hall series in marketing, OCLC: 22862097, Englewood Cliffs, N.J.: Prentice Hall, 1991, 711 pp., ISBN: 978-0-13-691247-7, URL: http://bvbr.bib-bvb.de:8991/F?func=service&doc_library=BVB01&doc_number=003866555&line_number=0001&func_code=DB_RECORDS&service_type=MEDIA.
- [23] Kotler, P. and Keller, K. L., *Marketing Management*, Google-Books-ID: UbftwEA-CAAJ, Pearson, 2016, 692 pp., ISBN: 978-0-13-385646-0.
- [24] Lalwani, P. et al., “Customer churn prediction system: a machine learning approach”, *Computing* 104 (2022-02-01), pp. 1–24, DOI: 10.1007/s00607-021-00908-y.
- [25] Maan, J. and Maan, H., “Customer Churn Prediction Model using Explainable Machine learning”, 11.1 (2023).
- [26] Malikireddy, V. P. and Kasa, M., “Customer churns prediction model based on machine learning techniques: a systematic review”, *3rd international conference on integrated intelligent computing communication & security (ICIIC 2021)*, Atlantis Press, 2021, pp. 167–174.
- [27] Murphy, K. P., *Machine Learning: A Probabilistic Perspective*, Google-Books-ID: NZP6AQAAQBAJ, MIT Press, Aug. 24, 2012, 1102 pp., ISBN: 978-0-262-01802-9.
- [28] Obiedat, R., “Developing Decision Tree based Models in Combination with Filter Feature Selection Methods for Direct Marketing”, *International Journal of Advanced Computer Science and Applications* 11.1 (2020), DOI: 10.14569/ijacsa.2020.0110180, URL: <https://doi.org/10.14569/ijacsa.2020.0110180>.
- [29] Object, o., “Ensemble of Feedforward Neural Networks Applied to Credit Default” (), URL: <https://core.ac.uk/reader/212991380> (visited on 12/01/2023).
- [30] Prokhorenkova, L. et al., “CatBoost: unbiased boosting with categorical features”, *Advances in Neural Information Processing Systems*, vol. 31, Curran Associates, Inc., 2018, URL: <https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html>.
- [31] Ren, Y. et al., “Robust softmax regression for multi-class classification with self-paced learning”, *Proceedings of the 26th International Joint Conference on Artificial Intelligence, IJCAI’17*, Melbourne, Australia: AAAI Press, 2017, pp. 2641–2647, ISBN: 978-0-9992411-0-3, (visited on 12/10/2023).
- [32] Saha, L. et al., “Deep churn prediction method for telecommunication industry”, *Sustainability* 15.5 (2023), Publisher: MDPI, p. 4543.

- [33] Sana, J. K. et al., “A novel customer churn prediction model for the telecommunication industry using data transformation methods and feature selection”, *Plos one* 17.12 (2022), Publisher: Public Library of Science San Francisco, CA USA, e0278095.
- [34] Sang, G. and Wu, S., “Predicting the Intention of Online Shoppers’ Purchasing”, *2022 5th International Conference on Advanced Electronic Materials, Computers and Software Engineering (AEMCSE)*, IEEE, Apr. 2022, DOI: 10.1109/aemcse55572.2022.00074, URL: <https://doi.org/10.1109/aemcse55572.2022.00074>.
- [35] Shabankareh, M. J. et al., “A stacking-based data mining solution to customer churn prediction”, *Journal of Relationship Marketing* 21.2 (2022), Publisher: Taylor & Francis, pp. 124–147.
- [36] Sharma, S. and Soni, H. K., “Discernment of Potential Buyers Based on Purchasing Behaviour Via Machine Learning Techniques”, *2020 IEEE International Conference on Advances and Developments in Electrical and Electronics Engineering (ICADEE)*, IEEE, Dec. 2020, DOI: 10.1109/icadee51157.2020.9368935, URL: <https://doi.org/10.1109/icadee51157.2020.9368935>.
- [37] Al-Shourbaji, I. et al., “Boosting ant colony optimization with reptile search algorithm for churn prediction”, *Mathematics* 10.7 (2022), Publisher: MDPI, p. 1031.
- [38] Sina Mirabdolbaghi, S. M. and Amiri, B., “Model Optimization Analysis of Customer Churn Prediction Using Machine Learning Algorithms with Focus on Feature Reductions”, *Discrete Dynamics in Nature and Society* 2022 (2022), Publisher: Hindawi.
- [39] *Stacking in Machine Learning*, OpenGenus IQ: Computing Expertise & Legacy, Apr. 17, 2021, URL: <https://iq.opengenus.org/stacking-in-machine-learning/>.
- [40] Subasi, A., “Chapter 3 - Machine learning techniques”, *Practical Machine Learning for Data Analysis Using Python*, ed. by Subasi, A., Academic Press, Jan. 1, 2020, pp. 91–202, ISBN: 978-0-12-821379-7, DOI: 10.1016/B978-0-12-821379-7.00003-5, URL: <https://www.sciencedirect.com/science/article/pii/B9780128213797000035>.
- [41] Sudharsan, R. and Ganesh, E. N., “A Swish RNN based customer churn prediction for the telecom industry with a novel feature selection strategy”, *Connection Science* 34.1 (2022-12-31), pp. 1855–1876, ISSN: 0954-0091, 1360-0494, DOI: 10.1080/09540091.2022.2083584, URL: <https://www.tandfonline.com/doi/full/10.1080/09540091.2022.2083584>.
- [42] Tariq, M. U. et al., “Distributed model for customer churn prediction using convolutional neural network”, *Journal of Modelling in Management* ahead-of-print (2021-06-01), DOI: 10.1108/JM2-01-2021-0032.
- [43] Tékouabou, S. C. et al., “Towards Explainable Machine Learning for Bank Churn Prediction Using Data Balancing and Ensemble-Based Methods”, *Mathematics* 10.14 (2022), Publisher: MDPI, p. 2379.

- [44] Teuwen, J. and Moriakov, N., “Convolutional neural networks”, *Handbook of Medical Image Computing and Computer Assisted Intervention*, Elsevier, 2020, pp. 481–501, ISBN: 978-0-12-816176-0, DOI: 10.1016/B978-0-12-816176-0.00025-9, URL: <https://linkinghub.elsevier.com/retrieve/pii/B9780128161760000259> (visited on 12/01/2023).
- [45] Usman-Hamza, F. E. et al., “Intelligent Decision Forest Models for Customer Churn Prediction”, *Applied Sciences* 12.16 (2022), Publisher: MDPI, p. 8270.
- [46] Wang, W. et al., “A User Purchase Behavior Prediction Method Based on XG-Boost”, *Electronics* 12.9 (Apr. 2023), p. 2047, DOI: 10.3390/electronics12092047, URL: <https://doi.org/10.3390/electronics12092047>.
- [47] Xu, J. et al., “SE-stacking: Improving user purchase behavior prediction by information fusion and ensemble learning”, *PLOS ONE* 15.11 (2020), Publisher: Public Library of Science, e0242629, ISSN: 1932-6203, DOI: 10.1371/journal.pone.0242629, URL: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0242629>.
- [48] Xu, T., Ma, Y., and Kim, K., “Telecom churn prediction system based on ensemble learning using feature grouping”, *Applied Sciences* 11.11 (2021), Publisher: MDPI, p. 4742.
- [49] Zhang, F., Keivanloo, I., and Zou, Y., “Data transformation in cross-project defect prediction”, *Empirical Software Engineering* 22 (2017), Publisher: Springer, pp. 3186–3218.
- [50] Zhou, Z.-H., *Ensemble methods: foundations and algorithms*, CRC press, 2012.